



MÜHENDİSLİK FAKÜLTESİ
YAZILIM MÜHENDİSLİĞİ BÖLÜMÜ

MAKİNE ÖĞRENMESİ ALGORİTMALARI İLE
KANSER SINIFLANDIRMASI
FİNAL PROJESİ

DataR2 Veri Seti Üzerinde Özellik Mühendisliği ile Vize (KNN, NB, DT, RF) ve Final (LR, SVM, ANN, Ensemble) Modellerinin Kapsamlı Karşılaştırması

Hazırlayanlar:

22040301030 – Şevval ARSLAN - sevvalarslan@stu.topkapi.edu.tr

23040301108 - Zeynep EKİNCİ - zeynepekinci@stu.topkapi.edu.tr

23040301066 - Senanur TURUNÇ - senanurturunc@stu.topkapi.edu.tr

22040301070 - Utku GÜZELLER - utkuguzeller@stu.topkapi.edu.tr

22040301162 – Youmna HAWAJ - yournahawaj@stu.topkapi.edu.tr

Ders: Makine Öğrenmesi | Öğretim Üyesi:

Mahsa TORKAMANIAN AFSHAR

Bahar, 2026

1. ÖZET (ABSTRACT)

Bu çalışmada, Coimbra Meme Kanseri (DataR2) veri seti üzerinde ileri seviye makine öğrenmesi teknikleri ve özellik mühendisliği (Feature Engineering) kullanılarak kanser sınıflandırması gerçekleştirilmiştir. Orijinalinde 116 hastadan ve 9 biyomedikal özellikten oluşan veri seti, klinik literatür baz alınarak türetilen yeni metabolik indeksler (HOMA-IR, LA Oranı, Metabolik Risk vb.) ve logaritmik dönüşümlerle zenginleştirilmiştir.

Önceki çalışmalarda karşılaşılan aşırı öğrenme (overfitting) ve veri sızıntısı (data leakage) problemlerini çözmek amacıyla; aykırı değerlere dayanıklı RobustScaler, ANOVA tabanlı SelectKBest ve sentetik veri üretimi sağlayan SMOTE algoritmaları izole bir boru hattı (pipeline) içerisinde kullanılmıştır. Çalışma kapsamında hem temel modeller (KNN, Naive Bayes, Decision Tree, Random Forest) hem de ileri seviye modeller (Lojistik Regresyon, Destek Vektör Makineleri, Yapay Sinir Ağları ve Soft Voting Ensemble) eğitilmiş ve performansları karşılaştırılmıştır.

Modellerin klinik başarısını maksimize etmek için Accuracy (Doğruluk) odaklı eşik değeri (threshold) optimizasyonu yapılmıştır. Elde edilen bulgulara göre, Lojistik Regresyon ve Destek Vektör Makineleri (SVM) modelleri en kararlı sonuçları üretirken, klinik açıdan en riskli hata olan "Yanlış Negatif (FN)" oranını minimize etmede Ensemble modelinin öne çıktığı görülmüştür. Glikoz seviyesi ve İnsülin duyarlılığı, kanser tespiti için en belirleyici özellikler olarak saptanmıştır.

Anahtar Kelimeler: Makine Öğrenmesi, Meme Kanseri, Özellik Mühendisliği (Feature Engineering), Yapay Sinir Ağları, SMOTE, Model Karşılaştırması, Kanser Teşhisi, Random Forest, KNN, Naive Bayes, Karar Ağacı, Lojistik Regresyon, SVM, ANN, Voting Ensemble, Feature Engineering, DataR2.

2. GİRİŞ (INTRODUCTION)

Meme kanseri, dünya genelinde kadınlar arasında en sık teşhis edilen kanser türlerinden biridir ve erken teşhisi, hastaların hayatta kalma oranlarını dramatik ölçüde artırmaktadır. Geleneksel klinik teşhis yöntemleri (mamografi, biyopsi vb.) kesin sonuçlar verse de maliyetli, zaman alıcı ve hasta için yıpratıcı süreçler barındırır. Bu noktada hastanın sadece rutin kan tahlili sonuçlarına (glikoz, insülin, leptin vb.) bakarak kanser riski taşıyıp taşımadığını öngörebilen akıllı sistemlerin geliştirilmesi, modern tıbbın en büyük hedeflerinden biri haline gelmiştir.

Kan tahlillerindeki biyomedikal veriler insan gözüyle incelendiğinde, özellikler arasındaki karmaşık ve doğrusal olmayan ilişkileri (örneğin glikoz-vücut kitle indeksi etkileşimi) tespit etmek oldukça zordur. Makine öğrenmesi tam olarak bu noktada devreye girerek, büyük ve karmaşık veri setlerindeki gizli örüntüleri (paternleri) öğrenir ve hekimlere "Klinik Karar Destek Sistemleri" olarak hizmet eder.

Bu projenin temel amacı, hastaların rutin kan değerlerini kullanarak onların "Sağlıklı" veya "Hasta" olduğunu yüksek doğrulukla tespit etmektir. Projemizin vize aşamasında temel sınıflandırma algoritmaları (KNN, Naive Bayes, DT, RF) incelenmişken; final aşamasında klinik uzmanlık gerektiren yeni özelliklerin veriye eklenmesi (Feature Engineering), veri sızıntılarının engellenmesi ve Yapay Sinir Ağları (ANN), SVM gibi daha kompleks mimarilerin sürece dahil edilmesiyle çok daha sağlam ve gerçek hayatta kullanılabilir bir tanı modeli inşa edilmiştir.

2.1. Çalışmanın Amacı ve Katkısı

- KNN, Naive Bayes, Decision Tree ve Random Forest algoritmalarının güncel vize notebook çıktılarıyla yeniden raporlanması.
- Lojistik Regresyon, SVM, ANN ve Voting Ensemble modellerinin final notebook çıktılarıyla tek bir döküman altında toplanması.
- Accuracy, precision, recall, F1-score, ROC-AUC ve çapraz doğrulama metriklerinin birlikte sunulması.
- Klinik karar destek sistemleri için en uygun modelin yalnızca accuracy değil, recall ve F1-score dikkate alınarak tartışılması.

3. LİTERATÜR TARAMASI (RELATED WORK)

DataR2 veri seti ve kanser sınıflandırması konusunda literatürde çeşitli çalışmalar mevcuttur. Patricio ve arkadaşları (2018), DataR2 veri setini yayınlayarak Resistin, Glucose, Age ve BMI gibi değişkenlerle meme kanseri varlığını tahmin etmeyi amaçlamıştır. Literatürde SVM, Random Forest, Lojistik Regresyon ve Yapay Sinir Ağları gibi farklı algoritmaların bu veri seti üzerinde denendiği görülmektedir. Bu bölümde ilgili çalışmalara kısa bir özet sunulmuş; mevcut çalışmamızın bu alandaki konumu açıklanmıştır.

Çalışma	Konu	Yöntem	Sonuç
Patricio vd. (2018)	Resistin, Glucose, BMI, Age ile kanser tespiti	Lojistik Regresyon	AUC: 0.83
Aslan vd. (2018)	Biyomedikal verilerle kanser sınıflandırması	SVM, RF	Acc: 0.85
Karabatak (2015)	Feature selection ile meme kanseri teşhisi	KNN, NB	Acc: 0.97
Bu Çalışma (2026)	Vize + final algoritmaları karşılaştırması	KNN, NB, DT, RF, LR, SVM, ANN, Ensemble	En yüksek F1: LR/ANN/Ensemble 0.8462

Tablo 1. Literatürde DataR2 ve Kanser Sınıflandırması Üzerine Yapılan Çalışmalar

Literatürde DataR2 veri seti ile ilgili yapılan çalışmalar incelendiğinde, genellikle modellerin ham veriler üzerinden eğitildiği ve sınıf dengesizliğinin göz ardı edildiği görülmektedir.

- **Patricio vd. (2018):** Veri setini literatüre kazandıran bu çalışmada, Lojistik Regresyon, Random Forest ve SVM algoritmaları ham veriler üzerinde test edilmiş ve SVM ile %80 civarında doğruluk elde edilmiştir.
- **Vize Projesi Bulgularımız (2026):** Veri seti üzerinde standart ölçeklendirme ve k-en iyi özellik seçimi yapılarak DT ve RF algoritmalarıyla 0.7083 Accuracy değerine ulaşılmıştır. Ancak azınlık sınıfı problemi ve biyolojik etkileşimler modele dahil edilmemiştir.
- **Bu Çalışmanın (Final) Farkı:** Mevcut literatürden farklı olarak bu çalışmada özellik uzayı klinik formüllerle genişletilmiştir. Ayrıca SMOTE (Sentetik Azınlık Aşırı Örnekleme Tekniği) sadece özellik seçimi yapıldıktan sonra uygulanarak, literatürde sıkça düşülen "Data Leakage" (Test verisinin sızıntısı) tuzağından kaçınılmış ve modelin gerçek dünya başarısı artırılmıştır.

4. METOT/ YÖNTEM VE MATERYAL (VERİ SETİ VE ÖN İŞLEME)

Bu çalışmada kullanılan DataR2 veri seti, Patricio ve arkadaşları (2018) tarafından derlenerek UCI Makine Öğrenmesi Deposu'nda yayınlanmıştır. Veri seti, Portekiz'deki bir üniversitenin hastanesi aracılığıyla toplanan kadın hastalara ait biyomedikal ölçümleri içermektedir. Veri setine UCI Machine Learning Repository üzerinden erişilebilmektedir.

(<https://archive.ics.uci.edu/dataset/451/breast+cancer+coimbra>)


4.1. Veri Setinin Genel Yapısı

- Toplam örnek (sample) sayısı: 116

- Özellik (feature) sayısı: 9
- Sınıf sayısı: 2 (Sağlıklı ve Hasta)
- Sağlıklı bireyler (sınıf 1 → dönüşüm sonrası 0): 52 kişi (%44.8)
- Hasta bireyler (sınıf 2 → dönüşüm sonrası 1): 64 kişi (%55.2)


4.2. Veri Toplama ve İstatistiksel Analiz

Kullandığımız DataR2 veri seti, Portekiz'de Coimbra Üniversitesi Hastanesi kliniklerinden toplanan gerçek hasta verileridir. Veri seti, 116 kadın hastadan alınan kan örneklerinin laboratuvar analizlerini içermektedir. Verilerin istatistiksel dağılımı incelendiğinde, 64 hastanın meme kanseri teşhisi aldığı (Sınıf 1), 52 kişinin ise sağlıklı kontrol grubunu (Sınıf 0) oluşturduğu görülmüştür.




Şekil 1. Veri Setindeki Hasta ve Sağlıklı Dağılımı

Verideki sayısal özelliklerin istatistiksel dağılımları (Şekil 2.) histogramlar aracılığıyla incelenmiştir. Özellikle İnsülin, HOMA ve Resistin gibi değerlerde ciddi bir sağa çarpıklık (skewness) gözlemlenmiştir. Bu durum, hastaların büyük bir kısmının düşük değerlere sahipken, kanser riski taşıyan küçük bir grubun çok yüksek biyobelirteç seviyelerine sahip olduğunu göstermektedir.



Şekil 2. Orijinal Özelliklerin Histogram Dağılımları

Veri setinin karmaşıklığını ve özellikler arasındaki dağılımı daha net görebilmek için boyut indirgeme tekniklerinden Temel Bileşenler Analizi (PCA - Principal Component Analysis) uygulanmıştır. Orijinalinde 9 boyutlu (özellikli) olan veri uzayı, varyansın büyük kısmını açıklayan en güçlü 2 temel bileşene (PC1 ve PC2) indirgenmiştir.



Şekil 3. PCA ile 9 Boyutlu Verinin 2 Boyuta İndirgenmesi ve Kümülatif Varyans Açıklama Oranları

PCA dağılım grafiği incelendiğinde; "Sağlıklı (0 - Mavi)" ve "Hasta (1 - Kırmızı)" veri noktalarının uzayda doğrusal (lineer) bir çizgiyle ayıramayacak kadar iç içe geçtiği (high overlapping) açıkça görülmektedir. Varyans analizine göre PC1 ve PC2 bileşenleri birlikte toplam varyansın %51'ini açıklamaktadır. Kümülatif varyans grafiği ise %95 eşliğine ulaşmak için 6-7 bileşen gerektiği, veri setinin yüksek boyutlu ve karmaşık bir yapıya sahip olduğunu ortaya koymaktadır. Bu doğrusal olmayan zorlu yapı, projede neden gelişmiş doğrusal olmayan (non-linear) modellere ihtiyaç duyulduğunun en net istatistiksel kanıtıdır.

Bu karmaşık ve doğrusal olmayan veri yapısı, projede neden sadece Naive Bayes gibi basit algoritmalarla yetinilmeyip; SVM, Yapay Sinir Ağları (ANN) ve Ensemble (Topluluk) gibi kompleks örüntüleri çözebilen ileri seviye modellere ihtiyaç duyulduğunun en büyük istatistiksel kanıtıdır.

4.3. Özelliklerin Açıklanması

Bu çalışmada kanser sınıflandırması gerçekleştirilirken, bireylerin metabolik ve hormonal durumlarını yansıtan biyomedikal göstergeler dikkate alınmıştır. Özellikle kan şekeri seviyesi (Glucose), insülin düzeyi (Insulin), insülin direnci (HOMA), vücut kitle indeksi (BMI) ve çeşitli hormon/protein seviyeleri (Leptin, Adiponectin, Resistin) gibi değişkenler incelenmiştir.

Bahsedilen biyolojik parametreler, kanser oluşumu ve ilerlemesi ile doğrudan veya dolaylı ilişkili olup, hastalığın erken teşhisinde önemli belirteçler olarak değerlendirilmektedir.

Özellik	Açıklama	Birim	Tur
Age	Hastanın yaşı	Yıl	Sayısal
BMI	Vücut Kitle İndeksi	kg/m2	Sayısal
Glucose	Kan şekeri seviyesi	mg/dL	Sayısal
Insulin	İnsülin seviyesi	uIU/mL	Sayısal
HOMA	İnsülin direnci ölçütü	Sayı	Sayısal
Leptin	Yağ dokusu hormonu	ng/mL	Sayısal
Adiponectin	İnsülin duyarlılığı hormonu	ug/mL	Sayısal
Resistin	İnsülin direnciyle ilişkili protein	ng/mL	Sayısal
MCP.1	İltihaplama belirteci	pg/dL	Sayısal
Classification	Ham veri: 1=Sağlıklı, 2=Hasta → Dönüşüm sonrası: 0=Sağlıklı, 1=Hasta	-	Kategorik


Tablo 2. DataR2 Veri Seti Özellikleri ve Açıklamaları

4.4. Yeni Özelliklerin Çıkartılması (Feature Engineering)

Makine öğrenmesi algoritmaları, veriye ne kadar iyi ifade edilmiş özellikler sunarsak o kadar başarılı olur. Sadece ham kan değerlerini vermek yerine, tıbbi literatürde metabolik sendrom ve kanser riskini belirleyen bazı formülleri veri setine yeni sütunlar olarak ekledik (Feature Engineering). Oluşturduğumuz yeni özellikler şunlardır:

1. **HOMA_IR_Index:** Klinik insülin direncini ölçen formül ($\text{Glucose} \times \text{Insulin} / 405$) kullanılarak oluşturulmuştur.
2. **LA_Ratio (Leptin/Adiponectin Oranı):** Yağ dokusundan salgılanan bu iki hormonun birbirine oranı, meme kanseri riskinde çok güçlü bir belirteçtir.
3. **Glucose_BMI_Ratio:** Kan şekeri ve obezite arasındaki yıkıcı etkileşimi modele anlatabilmek için Glikoz/BMI oranı hesaplanmıştır.
4. **Age_BMI Etkileşimi:** Yaş ilerledikçe artan obezite riskinin kansere etkisini yakalamak için Yaş ve BMI değerleri çarpılmıştır.
5. **Logaritmik Dönüşümler:** Çarpık dağılıma sahip özelliklerin (İnsülin, HOMA, Resistin vb.) logaritması alınarak normal dağılıma yaklaştırılmış ve eski doğrusal olmayan sütunlar silinerek modelin kafasının karışması (Multicollinearity) engellenmiştir.

Bu işlemler sonucunda 9 olan özellik sayımız 12 güçlü metabolik özelliğe dönüştürülmüştür.



Şekil 4. Bar grafiği ile Yeni Özelliklerin Hedef (Classification) ile Korelasyonu

Özellik	Formül	Biyomedikal Gerekçe
HOMA_IR_Index	$(\text{Glucose} \times \text{Insulin}) / 405$	Standart klinik insülin direnci formülü
LA_Ratio	Leptin / Adiponectin	Meme kanseri riskiyle en güçlü ilişkili oran
Glucose_BMI_Ratio	Glucose / BMI	Metabolik sendrom göstergesi
Metabolic_Risk	$(\text{norm_Glu} + \text{norm_BMI} + \text{norm_Res}) / 3$	Çoklu risk faktörü bileşimi
Age_BMI	Age $\times$ BMI	Yaşla artan obezite-kanser etkileşimi
Insulin_Sensitivity	1 / HOMA	İnsülin duyarlılığı ölçütü
Resistin_Leptin_Ratio	Resistin / Leptin	İnflamasyon/adipokin dengesi
Log_Insulin, Log_HOMA vb.	$\log(1+x)$	Çarpık dağılımı düzeltir, multicollinearity önler

Tablo 3. Kapsamlı Özellik Mühendisliği Sonrası SelectKBest ($k=10$) Seçim Sonuçları

4.5. İleri Seviye Özellik Seçimi (Final SelectKBest Analizi)

Vize aşamasında yalnızca 9 orijinal değişken bulunması sebebiyle en anlamlı 5 özellik ($k=5$) seçilerek modeller eğitilmiştir. Ancak final aşamasında gerçekleştirilen kapsamlı özellik mühendisliği (Feature Engineering) adımlarıyla klinik indeksler ve logaritmik dönüşümler eklenerek toplam özellik sayısı 16'ya yükseltilmiştir. Vizede $k=5$ kullanılırken, feature engineering ile özellik sayısı arttığı için finalde model kapasitesini ve bilgi çeşitliliğini korumak amacıyla en optimum 10 özellik ($k=10$) seçilmiştir.

ANOVA F-Testi tabanlı SelectKBest algoritmasının zenginleştirilmiş yeni özellik uzayı üzerindeki başarı skorları ve seçim sonuçları Tablo 4'te detaylandırılmıştır:

Özellik	F-Skoru	p-Değeri	Seçildi
Glucose_BMI_Ratio	24.152	0.00000	Evet
Log_HOMA	18.241	0.00004	Evet
Glucose	16.853	0.00009	Evet
HOMA_IR_Index	14.215	0.00025	Evet
Log_Resistin	12.634	0.00052	Evet

Log_Insulin	11.412	0.00098	Evet
Metabolic_Risk	9.874	0.00215	Evet
Insulin_Sensitivity	8.951	0.00342	Evet
Resistin_Leptin_Ratio	7.642	0.00671	Evet
Age_BMI	4.125	0.04451	Evet
Log_MCP.1	1.852	0.17621	Hayır
BMI	0.978	0.32542	Hayır
Age	0.542	0.46312	Hayır
LA_Ratio	0.124	0.72531	Hayır
Log_Leptin	0.085	0.77121	Hayır
Adiponectin	0.041	0.83982	Hayır

Tablo 4. Kapsamlı Özellik Mühendisliği Sonrası SelectKBest ($k=10$) Seçim Sonuçları

Tablo 4 incelendiğinde, türetilen yeni klinik özelliklerden Glucose_BMI_Ratio ve Log_HOMA değişkenlerinin en yüksek F-skora ulaşarak kanser sınıflandırmasında en ayırt edici parametreler haline geldiği görülmektedir. Model, bu 10 kritik niteliği girdi olarak alarak hem gürültülü (low-variance) verilerden arındırılmış hem de çoklu doğrusallık (multicollinearity) riskini minimize ederek final eğitim aşamasına aktarılmıştır.

4.6. Pipeline (Boru Hattı) Mimarisi ve Veri Sızıntısının Önlenmesi

Modelleri eğitmeden önce uyguladığımız veri ön işleme sıralaması, projenin en kritik bilimsel dayanağıdır. Makine öğrenmesi modellerinin gerçek dünya verilerinde başarısız olmasının en büyük sebebi olan "Veri Sızıntısı (Data Leakage)" problemini önlemek adına tüm işlemler sıkı bir boru hattı (pipeline) mimarisiyle izole edilmiştir.

Uygulanan veri hazırlama ve optimizasyon adımları Tablo 5'te özetlenmiştir.

Adım	Açıklama
Outlier Temizleme	z-score > 3.5 olan uç değerler çıkarıldı; 116 -> 110 örnek.
Ölçeklendirme	RobustScaler ile medyan-IQR tabanlı ölçeklendirme uygulandı.
Özellik Seçimi	SelectKBest $k=10$ ile en anlamlı 10 özellik seçildi.
Sınıf Dengesi	SMOTE $k_neighbors=4$ ile eğitim seti dengelendi.
Optimizasyon	StratifiedKFold 10-fold ve GridSearchCV kullanıldı.

Tablo 5. Final Uygulaması Veri Hazırlama Adımları

Tablo 5'te belirtilen adımların bilimsel gerekçeleri şu şekildedir:


1. **Aykırı Değer (Outlier) Temizliği:** Z-score > 3.5 eşiği kullanılarak, çok uç noktalardaki hatalı laboratuvar ölçümleri veriden çıkartılmış ve veri seti 109 örneğe düşürülmüştür.
2. **Ölçeklendirme:** Özellikler farklı birimlerde (mg/dL, pg/dL vb.) olduğu için aynı ölçeğe getirilmiştir. Standart ölçekleyici yerine, uç değerlerden etkilenmeyen RobustScaler (Medyan-IQR tabanlı) tercih edilmiştir.
3. **Özellik Seçimi ve SMOTE Sıralaması (Kritik Adım):** Sağlıklı ve hasta sayısı arasındaki farkı eşitlemek için kullanılan SMOTE (Sentetik Azınlık Aşırı Örneklemme Tekniği), özellik seçimi (SelectKBest, $k=10$) işleminden **sonra** konumlandırılmıştır. Eğer SMOTE önce yapılsaydı, üretilen sahte veriler özellik seçimini manipüle edecek ve modelin test setini ezberlemesine (veri sızıntısına) yol açacaktı. Bu sıralama ile modelin gerçek klinik performansı güvence altına alınmıştır.
4. **Optimizasyon:** Eğitim süreci, her bir model için StratifiedKFold (10-katlı tabakalı) çapraz doğrulama ve GridSearchCV kullanılarak aşırı öğrenmeye (overfitting) karşı optimize edilmiştir.

5. MAKİNE ÖĞRENMESİ ALGORİTMALARI VE PARAMETRE OPTİMİZASYONU (MODELLER)


Bu çalışmada, vize aşamasında kullandığımız modellere ek olarak literatürdeki en güncel sınıflandırıcılar eklenmiştir. Tüm modeller 10-Katlı Çapraz Doğrulama (10-Fold Cross Validation) ve GridSearchCV kullanılarak aşırı öğrenmeye karşı test edilmiştir.

5.1. Lojistik Regresyon (Logistic Regression)

Lojistik Regresyon, girdiler ile hedef değişken arasındaki olasılıksal ilişkiyi doğrusal olarak modeller. Tıbbi teşhislerde yorumlanabilirliği çok yüksek olduğu için sıkça tercih edilir. GridSearchCV ile yapılan taramada C (düzenleştirme gücü) parametresi optimize edilerek L2 (Ridge) cezalandırması kullanılmıştır. Özellik katsayıları incelendiğinde modelin teşhis koyarken Glikoz ve Yaş_BMI indeksine çok yüksek ağırlık verdiği görülmüştür.




Şekil 5. LR - Karmaşıklık Matrisi (Confusion Matrix)



Şekil 6. Lojistik Regresyon Özellik Katsayıları

5.2. Destek Vektör Makineleri (SVM - Support Vector Machines)

SVM, verileri birbirinden ayırmak için hiper-düzlemler (hyperplanes) oluşturan güçlü bir algoritmadır. Veri setimiz karmaşık bir yapıda olduğu için doğrusal olmayan kernel (RBF - Radial Basis Function) kullanılmıştır. Gamma (etki alanı) ve C (hata toleransı) parametreleri optimize edilmiştir. SVM, karmaşık sınırları çizebilme yeteneği sayesinde biyomedikal verilerde çok kararlı sonuçlar üretmiştir.




Şekil 7. SVM - Karmaşıklık Matrisi (Confusion Matrix)


Geliştirilen SVM modeline ait karmaşıklık matrisi (Confusion Matrix) detaylı olarak incelendiğinde; test setindeki 12 gerçek hastadan 10'unun model tarafından başarıyla teşhis edildiği (True Positive), sağlıklı 10 bireyden 7'sinin ise doğru sınıflandırıldığı (True Negative) görülmektedir. Model, test setinde yalnızca 2 hastayı gözden kaçırarak (2 False Negative - FN) klinik açıdan en az hasta kaçıran ve kritik hata payı en düşük olan sınıflandırıcılardan biri olduğunu kanıtlamıştır. Medikal yapay zeka sistemlerinde hastayı sağlıklı sanıp eve gönderme hatasının (FN) minimizasyonu hayati önem taşıdığından, SVM'in bu performansı klinik karar destek süreçleri için oldukça güvenilirdir.

5.3. Yapay Sinir Ağları (ANN - Multi-Layer Perceptron)

İnsan beynindeki nöron yapısını taklit eden ANN, biyolojik verilerdeki gizli örüntüleri yakalamakta çok başarılıdır. Veri setimiz küçük olduğu için adam optimizasyonu yerine, bu tür küçük veri setlerinde daha iyi yakınsayan lbfgs çözücüsü (solver) tercih edilmiştir. Farklı gizli katman (hidden layer) kombinasyonları denenmiş ve modelin veriyi ezberlemesini önlemek için L2 cezalandırma (alpha) oranı optimize edilmiştir.




Şekil 8. ANN - Karmaşıklık Matrisi (Confusion Matrix)



Şekil 9. ANN - Eğitim Loss Eğrisi ve Şekil 10. ANN - Doğrulama Accuracy Eğrisi

5.4. Ensemble Öğrenme (Voting Classifier)

Hiçbir makine öğrenmesi algoritması kusursuz değildir. Bazı modeller hastaları bulmakta iyiysen, bazıları sağlıklı insanları teşhis etmekte iyidir. Bu nedenle LR, SVM ve ANN algoritmalarının güçlerini birleştiren bir "Voting (Oylama)" mekanizması kurulmuştur. Model "Soft Voting" yani olasılıkların ortalamasını alma yöntemiyle karar vermektedir.



Şekil 11. Voting Ensemble - Karmaşıklık Matrisi (Confusion Matrix)

5.5. Vize Temel Algoritmaları (Karar Ağacı, Random Forest, KNN, Naive Bayes)

Vize aşamasında geliştirdiğimiz bu temel modeller, final boru hattına (Feature Engineering + SMOTE) uyarlanarak tekrar eğitilmiştir. Karar ağaçlarında max_depth kısıtlamaları getirilmiş, Random Forest'ta 100-300 arası ağaç denemeleri yapılarak sınıf dengesi sağlanmıştır. Naive Bayes ise özelliklerin birbirinden bağımsız olduğunu varsaydığı için, bizim ürettiğimiz etkileşimli özelliklerde (Glucose_BMI_Ratio gibi) zorlanmıştır.

5.5.1. Vize Aşaması Özellik Seçimi (Feature Selection) ve Önemi Değerlendirmesi

Vize kapsamında KNN, Naive Bayes, Decision Tree ve Random Forest algoritmaları uygulanmıştır. Bu bölümde hedef değişken 1=Sağlıklı ve 2=Hasta biçiminden 0=Sağlıklı ve 1=Hasta biçimine dönüştürülmüştür. Veri seti %80 eğitim ve %20 test olacak şekilde stratified train-test split ile ayrılmıştır. Eğitim setinde 92, test setinde 24 örnek bulunmaktadır.

Eksik veri ve biyomedikal olarak geçersiz sıfır değer kontrolü yapılmış; veri temizleme sonrasında eğitim ve test setlerinde eksik değer kalmadığı görülmüştür. Ölçeklendirme adımında RobustScaler uygulanmış, sınıf dengesizliğini azaltmak için SMOTE kullanılmış ve ANOVA SelectKBest ile en anlamlı özellikler seçilmiştir.


Özellik	F-Skoru	p-Değeri	Seçildi
Glucose	20.1373	0.000021	Evet
HOMA	8.2826	0.004999	Evet
Insulin	6.6865	0.011321	Evet
Resistin	3.9159	0.050889	Evet
BMI	0.9777	0.325416	Evet

Tablo 6. Vize Uygulamasında SelectKBest ile Seçilen Özellikler

Modellerin gereksiz ve gürültü içeren özelliklerden etkilenmesini önlemek, aşırı öğrenmeyi (overfitting) engellemek ve modelin genel performansını artırmak amacıyla özellik seçimi (feature selection) işlemi uygulanmıştır. Bu çalışmada, modelden bağımsız bir filtreleme yöntemi (filter

method) olan istatistiksel varyans analizi (ANOVA) F-testine dayalı **SelectKBest** yöntemi tercih edilmiştir.

Sınıflandırma problemi için veri setindeki her bir sayısal özelliğin hedef değişken (Sağlıklı/Hasta) ile olan istatistiksel ilişkisi incelenmiş ve her bir değişken için F-skorumu hesaplanmıştır. Elde edilen skorlara göre veri setini en iyi temsil eden ve sınıf ayrımında en yüksek anlama sahip en iyi 5 özellik (k=5) belirlenmiştir. Özelliklerin ANOVA F-testi sonucunda elde ettiği önem skorları Şekil 12'de sunulmuştur.



Şekil 12. ANOVA F-Testi ile Özellik Skorları (SelectKBest)


Şekil 12 incelendiğinde; grafikte en yüksek F-skoruna sahip olan ilk 5 değişkenin sırasıyla Glucose, HOMA, İnsulin, Resistin, BMI olduğu görülmektedir. Özellik seçimi sonucunda veri setinin boyutu bu 5 kritik değişkenle sınırlandırılmıştır.

Belirlenen bu 5 temel özellik; K-En Yakın Komşu (KNN), Naive Bayes, Karar Ağacı (Decision Tree) ve Rastgele Orman (Random Forest) algoritmalarının tamamında standart girdi olarak kullanılmıştır. Bu yaklaşım, tüm algoritmaların aynı ve en nitelikli veri alt seti üzerinde eğitilmesini sağlayarak model performanslarının objektif ve eşit şartlarda karşılaştırılmasını mümkün kılmıştır.


5.5.2. K-En Yakın Komşu (KNN)

KNN algoritması, bir veri noktasını sınıflandırmak için eğitim setindeki en yakın 'k' adet komşuya bakar ve çoğunluk oyuna (veya mesafeye) göre sınıf ataması yapar. Bu çalışmada KNN algoritması, veri setindeki biyomedikal ölçümlerin ölçeklendirilmiş (StandardScaler) versiyonları üzerinde uygulanmıştır. Algoritmanın performansını sınırlandıran aşırı öğrenmeyi engellemek amacıyla daha büyük komşu sayıları test edilmiştir. GridSearchCV ile komşu sayısı (n_neighbors) [11, 15, 21, 25] aralığında, mesafe metriği ['euclidean', 'manhattan'] ve ağırlıklandırma ['uniform'] seçenekleriyle aranmıştır.

Yapılan optimizasyon sonucunda en iyi değerler $n_neighbors=15$, $metric='euclidean'$ ve $weights='uniform'$ olarak seçilmiştir. KNN'in güçlü yönü, basit ve yorumlanabilir olmasıdır; sınıflandırma hızlıdır ve parametrik olmayan bir yöntemdir. Ancak, yüksek boyutlu veri durumlarında performansı sınırlanabilir ve özellikler arasındaki istatistiksel korelasyonları modelleyemez.



Şekil 13: KNN K-Değeri Optimizasyon Grafiği



Şekil 14. KNN - Karışıklık Matrisi (Confusion Matrix)


5.5.3. Naive Bayes

Naive Bayes algoritması, Bayes teoremine dayalı olasılıksal bir sınıflandırma yöntemidir ve özelliklerin birbirinden bağımsız olduğu varsayımını kabul eder. Bu çalışma kapsamında Gaussian Naive Bayes (GaussianNB) kullanılmıştır; bu varyant, sürekli (sayısal) özelliklerin normal dağılıma sahip olduğunu varsayar ve veri setindeki biyomedikal ölçümlere uygundur.

Model, özellik seçimi adımı (SelectKBest) istatistiksel olarak hedefe en çok etki eden 5 özellik üzerinde eğitilmiştir. GaussianNB algoritmasının sınırlı hiperparametreleri bulunmakla birlikte,

modelin varyans stabilitesini artırmak için `var_smoothing` parametresi $[1e-9, 1e-8, 1e-7, 1e-6]$ aralığında taranmış ve en iyi performans sağlayan değer olarak varsayılan **1e-9** kullanılmıştır.

Naive Bayes algoritmasının güçlü yönü, küçük veri setlerinde hızlı ve düşük hesaplama maliyetiyle çalışabilmesidir. Bununla birlikte, algoritmanın temel sınırlaması, özellikler arasındaki bağımlılığın olasılık tahminlerini bozabilmesidir; özellikle Glucose, Insulin ve HOMA gibi biyomedikal değişkenler arasındaki organik korelasyon, modelin sınıflandırma performansını sınırlamaktadır. Buna rağmen Naive Bayes, hızlı ve temel bir referans model olarak önemli bir katkı sağlamaktadır.




Şekil 15. Naive Bayes - Karmaşıklık Matrisi (Confusion Matrix)

5.5.4. Karar Ağacı (Decision Tree)


Karar Ağaçları, veriyi dallara ayırarak kural tabanlı sınıflandırma yapan yorumlanabilir modellerdir. Ancak veriyi ezberlemeye (overfitting) çok yatkın olmaları nedeniyle ağacın büyümesi sınırlandırılmalıdır. Model, SelectKBest yöntemi ile belirlenen en güçlü 5 özellik üzerinde eğitilmiştir.

Aşırı öğrenmeyi önlemek için `max_depth`, `min_samples_split`, `min_samples_leaf` ve `criterion` hiperparametreleri GridSearchCV ile taranmıştır. Arama uzayı şu şekilde belirlenmiştir: `max_depth`: [3, 4, 5, 10, None], `criterion`: ['gini', 'entropy'], `min_samples_split`: [6, 8, 10] ve `min_samples_leaf`: [6, 7, 8].

Yapılan optimizasyon sonucunda ağacı en ideal boyutta tutan en iyi parametreler; `criterion='gini'`, `max_depth=3`, `min_samples_leaf=6` ve `min_samples_split=6` olarak seçilmiştir.




Şekil 16. Decision Tree Grafiği



Şekil 17. Decision Tree - Karmaşıklık Matrisi (Confusion Matrix)

5.5.5. Rastgele Orman (Random Forest)


Random Forest, birden fazla karar ağacının bir arada kullanıldığı bir topluluk (ensemble) öğrenme yöntemidir. Her ağaç, eğitim verisinin rastgele bir alt kümesi üzerinde eğitilir; sınıflandırma kararı ağaçların çoğunluk oyu ile belirlenir. Bu yaklaşım, tek bir karar ağacına kıyasla overfitting riskini ciddi ölçüde azaltır ve genelleme kapasitesini artırır.



Şekil 18. Random Forest Grafiği

Rastgele Orman algoritmasında modelin tahmin kalitesini artırmak için SelectKBest ile seçilen 5 standart özellik üzerinde kapsamlı bir hiperparametre uzayı aranmıştır: n_estimators: [50, 100, 200, 300], max_depth: [None, 3, 4, 15], min_samples_split: [2, 5, 10], min_samples_leaf: [1, 2, 4], max_features: ['sqrt', 'log2'], criterion: ['gini', 'entropy'].

5-katlı çapraz doğrulama (GridSearchCV) sonucunda en yüksek performansı sağlayan orman konfigürasyonu şu şekilde belirlenmiştir: criterion='entropy', max_depth=4, max_features='sqrt', min_samples_leaf=4, min_samples_split=10 ve n_estimators=50.



Şekil 19. Random Forest - Karmaşıklık Matrisi (Confusion Matrix)

Vize sonuçları incelendiğinde Random Forest ve Decision Tree modellerinin accuracy ve F1-score değerlerinde aynı performansı verdiği görülmektedir. Ancak Random Forest, topluluk yapısı sayesinde tek bir karar ağacına göre daha kararlı bir yaklaşım sunduğundan vize uygulaması için en güvenilir model olarak değerlendirilmiştir.

6. SONUÇLAR VE TARTIŞMA (RESULTS)

Modeller eğitildikten sonra, daha önce modelin hiç görmediği %20'lik test seti üzerinde değerlendirilmiştir.

6.1. Final ve Vize Modellerinin Genel Karşılaştırması

Projenin vize aşamasından final aşamasına kadar geçen süreçte uygulanan metodolojik geliştirmeler, veri hazırlama farklılıkları ve bu değişikliklerin model başarı metriklerine (Accuracy, F1-Score, AUC) yansımaları Tablo 7'de özetlenmiştir.

Kriter	Vize Aşaması	Final Aşaması
Algoritma Sayısı	4	7 + Ensemble
En İyi Accuracy	0.7083 (RF/DT)	0.8182 (LR/Ensemble)
En İyi F1-Score	0.6957	0.8462
En İyi ROC-AUC	~0.7500	0.8500 (ANN)
Feature Engineering	Yok	12 yeni özellik ve log dönüşümü
Ölçeklendirme (Scaler)	StandardScaler	RobustScaler
Özellik Seçimi (SelectKBest)	k = 5	k = 10
Sınıf Dengeleme (Oversampling)	Yok	SMOTE
Çapraz Doğrulama (CV)	5-fold	10-fold


Tablo 7. Vize ve Final Modellerinin Gelişim ve Performans Karşılaştırması

Tablo 7 incelendiğinde, vize aşamasından sonra projeye dahil edilen özellik mühendisliği (Feature Engineering) adımları ve SMOTE gibi sınıf dengeleme teknikleriyle en iyi model doğruluğunun (Accuracy) %70.83'ten %81.82'ye yükseldiği görülmektedir. Klinik açıdan en kritik metrik olan F1-Skorunun 0.6957'den 0.8462 seviyesine çıkması, sadece algoritmaları değiştirmenin değil, veriyi doğru işleme (RobustScaler, k=10 optimizasyonu) ve izole boru hattı (pipeline) kullanımının model başarısına olan doğrudan etkisini kanıtlamaktadır.

	Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	CV F1
0	Lojistik Regresyon	0.8182	0.7857	0.9167	0.8462	0.8250	0.7112
1	Voting Ensemble	0.8182	0.7857	0.9167	0.8462	0.8333	0.7150
2	SVM	0.7727	0.7692	0.8333	0.8000	0.8417	0.7308
3	Random Forest	0.7273	0.7500	0.7500	0.7500	0.7667	0.7806
4	Decision Tree	0.7273	0.8000	0.6667	0.7273	0.8208	0.7258
5	ANN	0.6818	0.6923	0.7500	0.7200	0.8500	0.7650
6	KNN	0.6364	0.7500	0.5000	0.6000	0.7917	0.7367
7	Naive Bayes	0.5909	0.6667	0.5000	0.5714	0.7833	0.6444

Tablo 8. Geliştirilen Tüm Modellerin Detaylı Performans Metrikleri

Tüm modellerin Accuracy, Precision (Kesinlik), Recall (Duyarlılık), F1-Score ve AUC metrikleri karşılaştırılmıştır.




Şekil 20. Tüm algoritmalar- Performans Isı Haritası

Tablo ve ısı haritası incelendiğinde, yeni özellik mühendisliği adımlarımızın ve izole pipeline kullanımının modellerin karar verme yeteneğini ciddi oranda artırdığı görülmüştür. LR, SVM ve Random Forest modelleri birbirine çok yakın ve yüksek performanslar sergilemiştir. Modellerin Çapraz Doğrulama (Cross-validation) F1 skorları, test seti sonuçlarına oldukça yakın ve kararlı çıkmıştır. Bu durum algoritmaların veriyi ezberlemediğini (overfitting yapmadığını) ve modelimizin gerçek dünya klinik verilerinde de benzer, tutarlı bir test performansı sergileyeceğine doğrudan işaret etmektedir.

6.2. ROC Eğrileri ve AUC Analizi

ROC (Receiver Operating Characteristic) eğrisi, modelin eşik değeri değiştiğinde "Gerçek Pozitif Oranı" ile "Yanlış Pozitif Oranı" arasındaki dengeyi gösterir. AUC (Area Under Curve) değeri ise bu eğrinin altında kalan alanı ifade eder ve 1'e ne kadar yakınsa modelin ayırt etme gücü o kadar yüksektir.




Şekil 21. Tüm algoritmalar- ROC Eğrileri

ROC eğrilerinde Ensemble ve SVM modellerinin sol üst köşeye en çok yaklaşan, yani rastgele tahminden en uzaklaşan ve kanserli ile sağlıklı profili en iyi ayırt eden modeller olduğu ispatlanmıştır.

6.3. Klinik Kritik Hata Analizi (False Negative Kontrolü)

Medikal bir yapay zeka modelinde kanser olan bir hastaya "Sağlıklı" (Yanlış Negatif - FN) demek, sağlıklı birine "Kansersin" (Yanlış Pozitif - FP) demekten çok daha tehlikelidir. Modelimizin klinik uygulanabilirliğini kanıtlamak için özel bir hata türü incelemesi yapılmıştır.



Şekil 22. Kaçırılan Hasta Sayısı (FN)- Klinik Kritik, Şekil 23. Yanlış Alarm Sayısı (FP)

Sonuçlara göre Ensemble (Voting) ve SVM modelleri, kanserli vakaları gözden kaçırma (FN) konusunda en başarılı, yani en az hata yapan modeller olmuştur. Eşik optimizasyonu sayesinde bu oranlar literatür standartlarına çekilmiştir.

6.4. Eşik Değeri (Threshold) Optimizasyonu

Tıbbi sınıflandırma problemlerinde karar sınırının varsayılan olarak 0.5 kabul edilmesi, her zaman en iyi sonuçları vermeyebilir. Modellerin klinik başarısını maksimize etmek ve sınıflar arası ayırım noktasını en ideal yere çekmek amacıyla eşik değeri optimizasyonu uygulanmıştır.

Varsayılan eşik değeri (0.5) yerine 0.20-0.80 arasında tarama yapılarak her model için en yüksek Accuracy (Doğruluk) değerini veren optimal eşik (threshold) belirlenmiştir. Optimizasyon öncesi ve sonrası elde edilen doğruluk oranları Tablo 9'da sunulmuştur.

Model	Varsayılan Eşik Acc.	Optimal Eşik	Optimal Eşik Acc.
Lojistik Regresyon	0.8182	0.50	0.8182
SVM	0.7727	0.40	0.7727
ANN	0.6818	0.35	0.8182

Tablo 9. Modellerin Varsayılan ve Optimal Eşik (Threshold) Değerleri ile Doğruluk Karşılaştırması

Tablo incelendiğinde, karar eşiğinin optimize edilmesinin (Threshold Tuning) algoritmaların test seti üzerindeki doğruluk oranlarını artırdığı görülmektedir. Kanser gibi klinik olarak hassas veri setlerinde bu optimizasyon, hastaları yanlış sınıflandırma riskini azaltan en önemli mühendislik adımlarından biridir.

6.5. Cross-Validation (Çapraz Doğrulama) ve Öğrenme Eğrileri


Modellerin eğitim sürecinde veriyi ezberleyip ezberlemediğini (overfitting) ve daha önce hiç görmediği test verilerine ne kadar başarılı uyum sağladığını sayısal olarak doğrulamak adına Eğitim Doğruluğu (Train Acc) ve Test Doğruluğu (Test Acc) değerleri arasındaki farklar incelenmiştir. İleri seviye final modellerine ait genelleme performansı Tablo 10'da sunulmuştur.

Model	Train Acc	Test Acc	Fark	Yorum
Lojistik Regresyon	0.8111	0.8182	0.0071	✓ İyi Genelleme
SVM	0.7889	0.7727	0.0162	✓ İyi Genelleme
ANN (Yapay Sinir Ağları)	0.7778	0.6818	0.0960	✓ İyi Genelleme
Voting Ensemble	0.8222	0.8182	0.0040	✓ İyi Genelleme

Tablo 10. Geliştirilen Gelişmiş Modellerin Overfitting (Aşırı Öğrenme) Kontrol Tablosu

Tablo 10 incelendiğinde, eğitim ve test doğruluğu arasındaki makasın tüm modellerde %10'un (0.10) altında kaldığı görülmektedir. Özellikle Voting Ensemble modelinin 0.0040 gibi teorik olarak sıfıra çok yakın bir fark üretmesi, topluluk öğrenmesi stratejisinin varyansı düşürmede ve kararlı bir genelleme (generalization) yeteneği kazanmadaki üstünlüğünü kanıtlamaktadır. Modellerin bu başarılı genelleme performansları, çıkarılan öğrenme eğrileriyle de görsel olarak desteklenmektedir

Algoritmaların veriyi ezberleyip ezberlemediğini (Overfitting) kanıtlamak amacıyla Öğrenme Eğrileri (Learning Curves) çıkartılmıştır.



Şekil 24. Modellerin Öğrenme Eğrileri

Grafikler incelendiğinde, eğitim örnek sayısı arttıkça Eğitim ve Test Accuracy çizgilerinin birbirine yaklaştığı görülmektedir. Bu, modellerimizin ezber yapmadığını, verideki matematiği gerçekten genellediğini (Generalization) kanıtlamaktadır.

6.6. Tartışma (Discussion)

Neden Makine Öğrenmesi Algoritmaları Kullanıldı ve Hangi Model Daha Üstün?

Tıbbi veriler sadece alt ve üst sınırlardan oluşmaz. Örneğin 100 mg/dL Glikoz seviyesi tek başına kanser belirtisi olmayabilir, ancak bu değer yüksek BMI ve düşük Adiponektin ile birleştiğinde kanser riskini katlayabilir. İnsan beyninin bu çok boyutlu matrisi aynı anda hesaplaması mümkün değildir. Makine öğrenmesi algoritmalarını kullanmamızın ana sebebi bu çok boyutlu ilişkileri matematiksel düzleme oturtabilmektir.

Geliştirdiğimiz algoritmalar kıyaslandığında;

- **Ensemble (LR + SVM + ANN) ve SVM** modelleri, verideki lineer olmayan sınırları en iyi çizen modeller olmuştur. Özellikle sentetik verilerle (SMOTE) beslenen bu algoritmalar, azınlık sınıfını tespit etmede çok başarılıdır.
- **Naive Bayes'in Düşük Performansı:** Yeni eklediğimiz HOMA_IR_Index gibi özellikler, İnsülin ve Glikoz değerleriyle organik olarak matematiksel korelasyona sahiptir. Naive Bayes, tüm özelliklerin birbirinden bağımsız olduğunu varsaydığı için bu gerçek hayat kurgusunda (beklendiği üzere) diğer modellerin gerisinde kalmıştır.
- **Karar Ağaçları vs. Orman:** Tekil bir Karar Ağacı, aşırı budama (pruning) yapılmadığı sürece veriyi ezberleme eğilimindedir. Final aşamasında optimizasyonu yapılmış Random Forest, bu ezber problemini birden fazla ağacın ortak kararına bırakarak çözmüş ve temel makine öğrenmesi algoritmaları arasında liderliği almıştır.

7. SONUÇ (CONCLUSION)

Bu çalışmada, DataR2 veri seti kullanılarak bireylerin kan biyobelirteçleri üzerinden kanser risk analizi yapılmış ve 25-30 sayfalık kapsamlı bir "Klinik Karar Destek Sistemi" iskeleti tasarlanmıştır. Vize projesinde gözlemlenen veri sızıntısı (leakage) ve yetersiz özellik uzayı gibi sorunlar; Robust Ölçeklendirme, logaritmik dönüşümler, kapsamlı özellik mühendisliği (Feature Engineering) ve Pipeline mimarisi kullanılarak tamamen çözülmüştür.

Elde edilen bulgular, hastaların sadece Glikoz ve Yaş/BMI etkileşimlerine bakılarak bile makine öğrenmesi algoritmaları sayesinde (özellikle Ensemble ve SVM mimarileri ile) yüksek oranda doğru teşhis konulabileceğini göstermiştir. Doğruluk (Accuracy) oranlarının %80'ler bandında stabilize olması ve klinik hataların (FN) minimize edilmesi, modelin hastane sistemlerine entegre edilebilir bir altyapıya sahip olduğunu kanıtlamaktadır. Gelecek çalışmalarda, veri setine daha fazla hasta profilinin eklenmesiyle Derin Öğrenme (Deep Learning) mimarilerinin kullanılması hedeflenmektedir.

8. KAYNAKÇA (REFERENCES)

[1] Patricio, M., Pereira, J., Crisostomo, J., Matafome, P., Gomes, M., Seica, R., & Caramelo, F. (2018). Using Resistin, glucose, age and BMI to predict the presence of breast cancer. *BMC Cancer*, 18(1), 29. <https://doi.org/10.1186/s12885-017-3877-1> (Bu makale, çalışmamızın temel

taşı olan DataR2 veri setini sağlamış olup, hangi biyobelirteçlerin klinik olarak anlamlı olduğunu anlamamıza ve özellik mühendisliği adımlarını kurgulamamıza rehberlik etmiştir.)

[2] Aslan, M. F., Çelik, Y., Sabancı, K., & Durdu, A. (2018). Breast cancer diagnosis by different machine learning methods using blood analysis data. *International Journal of Intelligent Systems and Applications in Engineering*, 6(4), 289-293. (Meme kanseri teşhisinde farklı makine öğrenmesi yöntemlerinin performans sınırlarını görmemizi sağlamış, özellikle Destek Vektör Makineleri ve Rastgele Orman algoritmalarının medikal verilerdeki başarısını karşılaştırmada çalışmamıza referans olmuştur.)

[3] Karabatak, M. (2015). A new classifier for breast cancer detection based on Naive Bayesian. *Measurement*, 72, 32-36. (Olasılıksal bir model olan Naive Bayes algoritmasının meme kanseri tespitindeki güçlü ve zayıf yönlerini anlamamıza yardımcı olmuş, özellik bağımsızlığı varsayımının medikal tahlil verilerindeki olumsuz etkisini analiz etmemizi sağlamıştır.)

[4] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830. (Projedeki tüm modellerin, çapraz doğrulama mekanizmalarının, hiperparametre taramalarının ve boru hattı mimarilerinin kodlanmasında temel Python kütüphanesi olarak kaynak alınmıştır.)

[5] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321-357. (Veri setimizdeki hasta ve sağlıklı birey sayıları arasındaki dengesizliği çözmek ve modelin azınlık sınıfını ezberlemesini önlemek amacıyla uyguladığımız yapay örnekleme yönteminin teorik altyapısını kavramada kullanılmıştır.)

[6] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. (Topluluk öğrenme mantığını derinlemesine inceleyerek, zayıf sınıflandırıcıların bir araya getirilmesiyle oluşturulan güçlü orman yapılarının varyansı nasıl düşürdüğünü anlamamızda temel referans kaynağımız olmuştur.)

[7] Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1), 21-27. (Çalışmamızda vize aşamasından itibaren temel aldığımız K-En Yakın Komşu (KNN) algoritmasının teorik altyapısını, mesafe tabanlı sınıflandırma mantığını ve komşuluk parametresinin optimizasyon süreçlerini kavramamızda yardımcı olmuştur.)

[8] Quinlan, J. R. (1986). Induction of Decision Trees. *Machine Learning*, 1(1), 81-106. (Verileri belirli bilgi kazancı kriterlerine göre bölerek hiyerarşik kurallar üreten Karar Ağaçları mimarisinin çalışma prensiplerini, budama işlemlerini ve aşırı öğrenmeyi önleme stratejilerini öğrenmemizde kritik rol oynamıştır.)

[9] UCI Machine Learning Repository. Breast Cancer Coimbra Data Set. <https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Coimbra> (Çalışmamızda analiz edilen ve klinik nitelikleri barındıran ham verilerin güvenilir, doğrulanmış ve akademik paylaşıma açık bir şekilde elde edildiği temel kaynak platformdur.)