

İSTANBUL TOPKAPI ÜNİVERSİTESİ

MÜHENDİSLİK FAKÜLTESİ

YAZILIM MÜHENDİSLİĞİ BÖLÜMÜ

MAKİNE ÖĞRENMESİ ALGORİTMALARI İLE KANSER SINIFLANDIRMASI

*DataR2 Veri Seti Üzerinde KNN, Naive Bayes, Decision Tree ve Random Forest
Karşılaştırması*

Hazırlayanlar:

Şevval ARSLAN - 22040301030

Zeynep EKİNCİ - 23040301108

Senanur TURUNÇ - 23040301066

Utku GÜZELLER - 22040301070

Younna HAWAJ - 22040301162

Ders: Makine Öğrenmesi | Öğretim Üyesi:

Mahsa TORKAMANIAN AFSHAR

Bahar, 2026

1. ÖZET (ABSTRACT)

Bu çalışmada, DataR2 veri seti üzerinde makine öğrenmesi algoritmaları kullanılarak kanser sınıflandırması gerçekleştirilmiştir. Veri seti 116 hastadan oluşan 9 biyomedikal özellik içermekte; bireyler Sağlıklı (0) ve Hasta (1) olmak üzere iki sınıfa ayrılmaktadır.

Çalışma kapsamında K-En Yakın Komşu (KNN), Naive Bayes, Karar Ağaçları (Decision Tree) ve Rastgele Orman (Random Forest) algoritmaları uygulanmıştır. Modellerin performansını artırmak amacıyla özellik seçimi (**SelectKBest**) ve hiperparametre optimizasyonu (GridSearchCV) yöntemleri kullanılmıştır.

Elde edilen modeller; accuracy, precision, recall ve F1-score metrikleri kullanılarak değerlendirilmiştir. Sonuçlar, Random Forest ve Karar Ağacı algoritmalarının en yüksek doğruluk oranına (**0.7083**) ulaştığını göstermiştir. Ayrıca Glucose değişkeninin tüm modeller için en belirleyici özellik olduğu tespit edilmiştir.

Anahtar Kelimeler:

Makine Öğrenmesi, Sınıflandırma, Kanser Teşhisi, Random Forest, KNN, Naive Bayes, Karar Ağacı, Özellik Seçimi, DataR2

2. GİRİŞ (INTRODUCTION)

Kanser, hücrelerin kontrolsüz bir şekilde çoğalması ve normal hücre döngüsünün bozulması sonucu ortaya çıkan kompleks bir hastalık grubudur. Bu süreçte hücreler, büyüme sinyallerine bağımlı olmadan çoğalabilir ve çevre dokulara yayılabilir (metastaz).

Meme kanseri ise özellikle kadınlarda en sık görülen kanser türlerinden biri olup, meme dokusundaki hücrelerin anormal çoğalmasıyla gelişmektedir. Erken evrede tespit edildiğinde tedavi başarı oranı oldukça yüksek olmakla birlikte, geç teşhis durumunda hastalığın ilerlemesi ciddi riskler oluşturmaktadır. Bu nedenle erken teşhis, klinik süreçte kritik bir rol oynamaktadır.

Kanser, dünya genelinde en önemli sağlık sorunlarından biri olup erken teşhis, tedavi başarısını doğrudan etkileyen kritik bir faktördür. Geleneksel teşhis yöntemleri çoğu zaman zaman alıcı ve maliyetli olabilmektedir. Bu nedenle, makine öğrenmesi teknikleri son yıllarda tıbbi veri analizi ve hastalık sınıflandırması alanında önemli bir rol oynamaya başlamıştır.

Makine öğrenmesi algoritmaları, büyük veri setleri içerisindeki örüntüleri analiz ederek hastalıkların erken teşhisine katkı sağlayabilmektedir. Bu bağlamda, bu çalışmada DataR2 veri seti kullanılarak farklı sınıflandırma algoritmalarının performansı karşılaştırılmıştır.

2.1. Çalışmanın Amacı ve Katkısı

Bu çalışmanın temel amacı aşağıda maddeler halinde sunulmuştur:

- Dört farklı makine öğrenmesi algoritmasının aynı veri seti üzerinde karşılaştırılması
- Her algoritma için özellik seçimi ve hiperparametre optimizasyonu uygulanması
- Performans metriklerinin görsel ve sayısal olarak sunulması
- Klinik karar destek sistemleri için en uygun algoritmanın belirlenmesi

3. İLGİLİ ÇALIŞMALAR (RELATED WORK)

DataR2 veri seti ve kanser sınıflandırması konusunda literatürde çeşitli çalışmalar mevcuttur. Bu bölümde ilgili çalışmalara kısa bir özet sunulmuş; mevcut çalışmamızın bu alandaki konumu açıklanmıştır.

Çalışma	Konu	Yöntem	Sonuç
Patricio vd. (2018)	Resistin, Glucose, BMI, Age ile kanser tespiti	Lojistik Regresyon	AUC: 0.83
Aslan vd. (2018)	Biyomedikal verilerle kanser sınıflandırması	SVM, RF	Acc: 0.85
Karabatak (2015)	Feature selection ile meme kanseri teşhisi	KNN, NB	Acc: 0.97
Bu Çalışma (2026)	DataR2 ile 4 algoritma karşılaştırması	KNN, NB, DT, RF	Acc: 0.7083

Tablo 1. Literatürde DataR2 ve Kanser Sınıflandırması Üzerine Yapılan Çalışmalar


Patricio ve arkadaşları (2018), DataR2 veri setini ilk kez yayınlayarak lojistik regresyon ile 0.83 AUC değeri elde etmiştir [1]. Aslan ve arkadaşları (2018) SVM ve Random Forest algoritmalarını karşılaştırarak %85 doğruluk bildirmiştir [2]. Karabatak (2015) ise özellik seçimi ile KNN ve Naive Bayes algoritmalarının performansını incelemiştir [3]. Bu çalışma, bahsedilen yöntemleri bir arada uygulayarak kapsamlı bir karşılaştırma sunmaktadır.

DataR2 veri seti üzerinde yapılan diğer çalışmalarda, Lojistik Regresyon, Destek Vektör Makineleri (SVM) ve Yapay Sinir Ağları (ANN) gibi farklı makine öğrenmesi algoritmalarının da kullanıldığı görülmektedir. Bu çalışmalarda özellikle SVM ve Random Forest algoritmalarının yüksek doğruluk oranları elde ettiği rapor edilmiştir.

Literatürde bazı çalışmalar %85'in üzerinde doğruluk değerlerine ulaşırken, bu sonuçların genellikle daha farklı veri ön işleme teknikleri, özellik mühendisliği veya daha büyük veri setleri ile elde edildiği görülmektedir. Bu bağlamda mevcut çalışma, sınırlı veri seti üzerinde farklı algoritmaların karşılaştırmalı performansını sunarak literatüre katkı sağlamaktadır.

4. VERİ SETİ (DATA)

Bu çalışmada kullanılan DataR2 veri seti, Patricio ve arkadaşları (2018) tarafından derlenerek UCI Makine Öğrenmesi Deposu'nda yayınlanmıştır. Veri seti, Portekiz'deki bir üniversitenin hastanesi aracılığıyla toplanan kadın hastalara ait biyomedikal ölçümleri içermektedir. Veri setine UCI Machine Learning Repository üzerinden (<https://archive.ics.uci.edu/dataset/451/breast+cancer+coimbra>) erişilebilmektedir.



Şekil 1: Sınıflara Göre Özellik Dağılımları(Box-Plot)

4.1. Veri Setinin Genel Yapısı

- Toplam örnek (sample) sayısı: 116
- Özellik (feature) sayısı: 9
- Sınıf sayısı: 2 (Sağlıklı ve Hasta)
- Sağlıklı bireyler (sınıf 1 → dönüşüm sonrası 0): 52 kişi (%44.8)
- Hasta bireyler (sınıf 2 → dönüşüm sonrası 1): 64 kişi (%55.2)



Şekil 2: Pasta Grafiği Üzerinde Veri Setindeki Hasta ve Sağlıklı Dağılımı

4.2. Veri Ön İşleme

Veri setine aşağıdaki ön işleme adımları uygulanmıştır:

- **Eksik Veri Kontrolü:** Hiçbir sütunda (NaN/Null) eksik veriye rastlanmamıştır.
- **Sıfır Değer Kontrolü ve Giderme:** Biyomedikal açıdan sıfır olması imkansız olan değerler (Glucose, BMI vb. sütunlar) kontrol edilmiş; tespit edilen geçersiz sıfır değerleri ilgili sütunların ortalaması (mean) ile doldurularak veri bütünlüğü sağlanmıştır.
- **Encoding:** Veri setinde kategorik değişken bulunmadığı doğrulanmış; ilave bir encoding işlemine gerek duyulmamıştır.
- **Hedef Değişken Dönüşümü:** Classification sütunundaki 1 (Sağlıklı) ve 2 (Hasta) değerleri, makine öğrenmesi modellerine uygun olması amacıyla sırasıyla 0 ve 1 olarak yeniden kodlanmıştır.
- **Standardizasyon:** Model performanslarını optimize etmek için tüm özelliklere StandardScaler ile Z-Score normalizasyonu uygulanmıştır.
- **Özellik Seçimi (Feature Selection):** Modelin karmaşıklığını azaltmak ve başarıyı artırmak amacıyla ANOVA f-testine dayalı SelectKBest yöntemi (k=5) uygulanarak en anlamlı 5 özellik seçilmiştir.

- **Train-Test Bölünmesi:** Veri seti, %80 eğitim (92 örnek) ve %20 test (24 örnek) olacak şekilde ayrılmıştır. Sınıf dağılımı oranını korumak için tabakalı (stratified) bölünme kullanılmıştır.

5. ÖZELLİKLER (FEATURES)

Bu bölümde veri setindeki özellikler ve biyomedikal anlamları açıklanmış; uygulanan özellik seçimi yöntemi ile seçilen özellikler sunulmuştur.

Bu çalışmada kanser sınıflandırması gerçekleştirilirken, bireylerin metabolik ve hormonal durumlarını yansıtan biyomedikal göstergeler dikkate alınmıştır. Özellikle kan şekeri seviyesi (Glucose), insülin düzeyi (Insulin), insülin direnci (HOMA), vücut kitle indeksi (BMI) ve çeşitli hormon/protein seviyeleri (Leptin, Adiponectin, Resistin) gibi değişkenler incelenmiştir.

Bahsedilen biyolojik parametreler, kanser oluşumu ve ilerlemesi ile doğrudan veya dolaylı ilişkili olup, hastalığın erken teşhisinde önemli belirteçler olarak değerlendirilmektedir.

5.1. Özelliklerin Açıklanması


Tablo 2. DataR2 Veri Seti Özellikleri ve Açıklamaları

Özellik	Açıklama	Birim	Tür
Age	Hastanın yaşı	Yıl	Sayısal
BMI	Vücut Kitle İndeksi	kg/m ²	Sayısal
Glucose	Kan şekeri seviyesi	mg/dL	Sayısal
Insulin	İnsülin seviyesi	uIU/mL	Sayısal
HOMA	İnsülin direnci ölçütü	Sayı	Sayısal
Leptin	Yağ dokusu hormonu	ng/mL	Sayısal
Adiponectin	İnsülin duyarlılığı hormonu	ug/mL	Sayısal
Resistin	İnsülin direnciyle ilişkili protein	ng/mL	Sayısal
MCP.1	İltihaplama belirteci	pg/dL	Sayısal
Classification	Ham veri: 1=Sağlıklı, 2=Hasta → Dönüşüm sonrası: 0=Sağlıklı, 1=Hasta	-	Kategorik

5.2. Özellik Seçimi (Feature Selection)

Modellerin gereksiz ve gürültü içeren özelliklerden etkilenmesini önlemek, aşırı öğrenmeyi (overfitting) engellemek ve modelin genel performansını artırmak amacıyla özellik seçimi (feature selection) işlemi uygulanmıştır. Bu çalışmada, modelden bağımsız bir filtreleme yöntemi (filter method) olan istatistiksel varyans analizi (ANOVA) F-testine dayalı **SelectKBest** yöntemi tercih edilmiştir.

Sınıflandırma problemi için veri setindeki her bir sayısal özelliğin hedef değişken (Sağlıklı/Hasta) ile olan istatistiksel ilişkisi incelenmiş ve her bir değişken için F-skorları hesaplanmıştır. Elde edilen skora göre veri setini en iyi temsil eden ve sınıf ayırımında en yüksek anlama sahip **en iyi 5 özellik (k=5)** belirlenmiştir. Özelliklerin ANOVA F-testi sonucunda elde ettiği önem skorları **Şekil 3**'de sunulmuştur.



Şekil 3. ANOVA F-Testi ile Özellik Skorları (SelectKBest)

Şekil 3 incelendiğinde; grafikte en yüksek F-skoruna sahip olan ilk 5 değişkenin sırasıyla **Glucose, HOMA, Insulin, Resistin, BMI** olduğu görülmektedir. Özellik seçimi sonucunda veri setinin boyutu bu 5 kritik değişkenle sınırlandırılmıştır.

Belirlenen bu 5 temel özellik; K-En Yakın Komşu (KNN), Naive Bayes, Karar Ağacı (Decision Tree) ve Rastgele Orman (Random Forest) algoritmalarının tamamında standart girdi olarak kullanılmıştır. Bu yaklaşım, tüm algoritmaların aynı ve en nitelikli veri alt seti üzerinde eğitilmesini sağlayarak model performanslarının objektif ve eşit şartlarda karşılaştırılmasını mümkün kılmıştır.


6. MODELLER (MODELS)

Bu bölümde uygulanan dört makine öğrenmesi algoritması (KNN, Naive Bayes, Karar Ağacı ve Rastgele Orman) açıklanmış; her algoritma için uygulanan hiperparametre optimizasyon süreçleri ve seçilen en iyi parametreler sunulmuştur. Modellerin hiperparametre ayarları, aşırı öğrenmeyi (overfitting) kontrol altında tutmak ve en yüksek performansı elde etmek amacıyla GridSearchCV kullanılarak 5 katlı çapraz doğrulama (5-Fold CV) yöntemiyle optimize edilmiştir. Modellerin eğitiminde, özellik seçimi aşamasında (SelectKBest) belirlenen en anlamlı 5 özellik standart girdi olarak kullanılmıştır.

6.1. K-En Yakın Komşu (KNN)

KNN algoritması, bir veri noktasını sınıflandırmak için eğitim setindeki en yakın 'k' adet komşuya bakar ve çoğunluk oyuna (veya mesafeye) göre sınıf ataması yapar. Bu çalışmada KNN algoritması, veri setindeki biyomedikal ölçümlerin ölçeklendirilmiş (StandardScaler) versiyonları üzerinde uygulanmıştır. Algoritmanın performansını sınırlandıran aşırı öğrenmeyi engellemek amacıyla daha büyük komşu sayıları test edilmiştir. GridSearchCV ile komşu sayısı (n_neighbors) [11, 15, 21, 25] aralığında, mesafe metriği ['euclidean', 'manhattan'] ve ağırlıklandırma ['uniform'] seçenekleriyle aranmıştır.

Yapılan optimizasyon sonucunda en iyi değerler **n_neighbors=15**, **metric='euclidean'** ve **weights='uniform'** olarak seçilmiştir. KNN'in güçlü yönü, basit ve yorumlanabilir olmasıdır; sınıflandırma hızlıdır ve parametrik olmayan bir yöntemdir. Ancak, yüksek boyutlu veri durumlarında performansı sınırlanabilir ve özellikler arasındaki istatistiksel korelasyonları modelleyemez.




Şekil 4: KNN K-Değeri Optimizasyon Grafiği

6.2. Naive Bayes

Naive Bayes algoritması, Bayes teoremine dayalı olasılıksal bir sınıflandırma yöntemidir ve özelliklerin birbirinden bağımsız olduğu varsayımını kabul eder. Bu çalışma kapsamında Gaussian Naive Bayes (GaussianNB) kullanılmıştır; bu varyant, sürekli (sayısal) özelliklerin normal dağılıma sahip olduğunu varsayar ve veri setindeki biyomedikal ölçümlere uygundur.

Model, özellik seçimi adımı (SelectKBest) istatistiksel olarak hedefe en çok etki eden 5 özellik üzerinde eğitilmiştir. GaussianNB algoritmasının sınırlı hiperparametreleri bulunmakla birlikte, modelin varyans stabilitesini artırmak için `var_smoothing` parametresi $[1e-9, 1e-8, 1e-7, 1e-6]$ aralığında taranmış ve en iyi performans sağlayan değer olarak varsayılan **1e-9** kullanılmıştır.

Naive Bayes algoritmasının güçlü yönü, küçük veri setlerinde hızlı ve düşük hesaplama maliyetiyle çalışabilmesidir. Bununla birlikte, algoritmanın temel sınırlaması, özellikler arasındaki bağımlılığın olasılık tahminlerini bozabilmesidir; özellikle Glucose, Insulin ve HOMA gibi biyomedikal değişkenler arasındaki organik korelasyon, modelin sınıflandırma performansını sınırlamaktadır. Buna rağmen Naive Bayes, hızlı ve temel bir referans model olarak önemli bir katkı sağlamaktadır.



Şekil 6:Random Forest Grafiği

Rastgele Orman algoritmasında modelin tahmin kalitesini artırmak için SelectKBest ile seçilen 5 standart özellik üzerinde kapsamlı bir hiperparametre uzayı aranmıştır: `n_estimators`: [50, 100, 200, 300], `max_depth`: [None, 3, 4, 15], `min_samples_split`: [2, 5, 10], `min_samples_leaf`: [1, 2, 4], `max_features`: ['sqrt', 'log2'], `criterion`: ['gini', 'entropy'].

5-katlı çapraz doğrulama (GridSearchCV) sonucunda en yüksek performansı sağlayan orman konfigürasyonu şu şekilde belirlenmiştir: **`criterion='entropy'`**, **`max_depth=4`**, **`max_features='sqrt'`**, **`min_samples_leaf=4`**, **`min_samples_split=10`** ve **`n_estimators=50`**.

7. SONUÇLAR (RESULTS)

7.1. Performans Metrikleri Karşılaştırması


Uygulanan dört makine öğrenmesi algoritmasının (SelectKBest ile seçilen 5 özellik üzerinden) test veri seti üzerindeki performans metrikleri Tablo 3'te sunulmuştur. Hem Karar Ağacı hem de Rastgele Orman algoritmaları benzer doğruluk oranlarıyla en yüksek performansı göstermiş olup, tablo sonuçları detaylandırılmıştır.

Algoritma	Accuracy	Precision	Recall	F1-Score
KNN	0.6250	0.7000	0.5385	0.6087

Algoritma	Accuracy	Precision	Recall	F1-Score
Naive Bayes	0.6250	0.8333	0.3846	0.5263
Decision Tree	0.7083	0.8000	0.6154	0.6957
Random Forest	0.7083	0.8000	0.6154	0.6957

Tablo 3. Algoritmaların Performans Metrikleri Karşılaştırması

Tablo 3 incelendiğinde; Decision Tree ve Random Forest algoritmalarının accuracy (0.7083) ve F1-Score (0.6957) metriklerinde en yüksek skorları elde ettiği görülmektedir. F1-Score'un dengeli yapısı ve ensemble (topluluk) tabanlı bir algoritma olması sebebiyle, Random Forest modeli bu veri seti için en başarılı ve güvenilir sınıflandırıcı olarak belirlenmiştir.




Şekil 7: Tüm Modellerin Performans Karşılaştırması

7.2. Overfitting Analizi (Aşırı Öğrenme)

Modellerin eğitim setini ezberleyip ezberlemediğini kontrol etmek amacıyla overfitting analizi yapılmıştır. En başarılı model olarak seçilen Random Forest incelendiğinde; modelin eğitim veri setindeki doğruluğunun oldukça yüksek (0.9239) olduğu, test doğruluğunun ise 0.7083 seviyesinde gerçekleştiği görülmüştür.

Eğitim ve test arasındaki bu fark incelendiğinde; GridSearchCV'nin seçtiği max_depth=4 ve n_estimators=50 gibi kısıtlayıcı (büyümeyi engelleyici) hiperparametrelere rağmen bir miktar performans düşüşü gözlemlenmiştir. Bu durum

modelin yapısal zafiyetinden ziyade, DataR2 veri setinin örneklem sayısının görece küçük olmasından (116 örnek) kaynaklanmaktadır. Modelin gerçek genelleme kapasitesini test seti skoru kadar, eğitim aşamasında elde edilen **5-katlı çapraz doğrulama (CV) skoru olan 0.7836** değeri de güvenilir bir biçimde yansıtmaktadır.



Şekil 8: Tüm Modellerin Aşırı Öğrenmede (Overfitting) Kontrolü


7.3. Özellik Önem Analizi (Feature Importance)

Ön işleme aşamasında uygulanan ANOVA (SelectKBest) analizi ve sonrasında eğitilen Random Forest modelinin içsel karar mekanizmaları bir arada incelendiğinde; model kararlarını etkileyen **en önemli değişkenin açık ara Glucose (Glikoz)** olduğu tespit edilmiştir.

Glucose değişkenini sırasıyla Resistin, BMI (Vücut Kitle İndeksi) değişkenleri takip etmektedir. Bu bulgular; kan şekeri seviyesinin (Glucose) ve insülin direnciyle bağlantılı olan proteinlerin (Resistin), veri setindeki kadın hastalarda meme kanseri sınıflandırması ve teşhisinde en belirleyici biyomedikal göstergeler olduğunu istatistiksel olarak kanıtlamaktadır.

7.4. Değişkenler Arası Korelasyon Analizi

Modellerin sınıflandırma kararlarını nasıl verdiğini ve biyomedikal özelliklerin birbirleriyle olan istatistiksel ilişkilerini daha derinlemesine incelemek amacıyla değişkenler arası korelasyon analizi yapılmıştır. Şekil 9'da, özellikler arasındaki doğrusal ilişkilerin gücünü ve yönünü gösteren Pearson Korelasyon Matrisi sunulmuştur.



Şekil 9: Biyomedikal Özellikler ve Hedef Değişken (Classification) Arasındaki Pearson Korelasyon Matrisi

Korelasyon matrisleri incelendiğinde modellerin performansını doğrudan etkileyen şu kritik bulgular elde edilmiştir:

- **Hedef Değişkenle (Classification) Olan İlişki:** Hedef değişken olan kanser durumuyla en belirgin pozitif korelasyona sahip olan özelliğin **Glucose (Glikoz)** olduğu görülmektedir. Bu bulgu, Bölüm 7.3'te Random Forest algoritmasının Glikoz'u en ayırt edici özellik olarak belirlemesini doğrulamaktadır.
- **İnsülin ve HOMA Arasındaki Yüksek Bağımlılık (Multicollinearity):** Matristeki en dikkat çekici detay, **Insulin** ve **HOMA** değişkenleri arasında mükemmele yakın pozitif bir korelasyon (koyu renkli/kırmızımsı alan) bulunmasıdır. HOMA indeksinin formül olarak zaten insülin değerine bağlı

hesaplanmasından kaynaklanan bu "çoklu doğrusallık" (multicollinearity) durumu, özelliklerin birbirinden tamamen bağımsız olduğunu varsayan **Naive Bayes** modelinin bu veri setinde neden düşük performans gösterdiğini (Bkz. Bölüm 8.2) kanıtlar niteliktedir.

- **Diğer Biyomedikal İlişkiler:** Vücut Kitle İndeksi (BMI) ile Leptin hormonu arasında da orta şiddette pozitif bir korelasyon gözlemlenmiştir. Bu durum, artan yağ dokusuyla (BMI) birlikte salgılanan leptin miktarının artması şeklindeki tıbbi beklentiyle örtüşmektedir.


Yapılan bu korelasyon analizi, veri seti içerisindeki biyomedikal dinamiklerin model performanslarına (özellikle Karar Ağaçlarının neden başarılı, Naive Bayes'in neden başarısız olduğuna) olan etkisini açıkça ortaya koymuştur.

8. TARTIŞMA VE KARAR (DISCUSSION)

8.1. Hangi Algoritma Daha İyi Çalışıyor?

Tablo 3'teki sonuçlara göre Karar Ağacı (Decision Tree) ve Rastgele Orman (Random Forest) algoritmaları, en yüksek doğruluk (0.7083) ve F1 skoru (0.6957) değerlerini elde ederek test veri setinde başa baş bir performans sergilemiştir. Her iki modelin de aynı 5 özellik seti üzerinde eğitilmesine ve aynı test metriklerine ulaşmasına rağmen, nihai olarak en başarılı model **Random Forest** kabul edilmiştir.

Bunun temel nedeni, Random Forest'ın topluluk (ensemble) yapısıdır. Karar Ağacı tek bir ağaç yapısına sahip olduğu için veriyi ezberlemeye (overfitting) çok daha yatkındır ve yeni verilerde performans dalgalanmaları yaşayabilir. Random Forest ise algoritmik hataları birden fazla ağacın çoğunluk oylaması yoluyla dengelediği için, klinik karar destek sistemleri (kanser teşhisi vb.) gibi kritik alanlarda genelleme kapasitesi çok daha yüksek, kararlı ve güvenilir bir modeldir.



Şekil 10: Tüm Modeller-Confusion Matrix Grafiği

8.2. Diğer Algoritmalar Neden Düşük Çıktı?


Naive Bayes ve KNN algoritmaları (0.6250 Accuracy) ağaç tabanlı modellere göre daha düşük performans sergilemiştir. Naive Bayes algoritmasının göreceli olarak düşük sonuç vermesinin temel nedeni, algoritmanın tüm özelliklerin birbirinden istatistiksel olarak bağımsız olduğunu varsaymasıdır. Ancak bu veri setinde tıbbi özellikler arasında anlamlı organik korelasyonlar (örneğin Glikoz-İnsülin veya İnsülin-HOMA) bulunmaktadır. Bu temel varsayımın ihlal edilmesi, modelin olasılık tahminlerini olumsuz yönde etkilemektedir.

KNN (K-En Yakın Komşu) algoritmasının performansı ise, veri setinin küçük olması ve özellik uzayında mesafe hesaplamasının hassasiyetini yitirmesiyle sınırlanmıştır. Standardizasyon (Z-Score) işlemi uygulanmasına ve $k=15$ gibi optimal bir komşu sayısı bulunmasına rağmen, 116 örneklik bu veri setinde KNN için sınıfları net bir şekilde ayıracak yeterli ve yoğun bir komşu dağılımı sağlanamamıştır.

8.3. Genel Değerlendirme

Tüm algoritmalar için sonuçları kısıtlayan en temel ortak faktör, veri setinin örneklem hacminin küçük olması (toplam 116 örnek) ve sınıflar arasında hafif bir dengesizlik (52 sağlıklı, 64 hasta) bulunmasıdır. Tıbbi veri setlerindeki bu kısıtlılık, modellerin %85-90 gibi çok yüksek doğruluk oranlarına ulaşmasını engellemiştir.

Özellik seçimi analizi ve model performansları bir arada değerlendirildiğinde; kanser sınıflandırmasında Glikoz, Resistin, Vücut Kitle İndeksi (BMI) ve Yaş faktörlerinin en ayırt edici göstergeler olduğu saptanmıştır. Daha büyük bir katılımcı grubu ve daha dengeli bir veri setiyle tüm algoritmaların performansının artması beklenmektedir. Mevcut şartlar ve metrikler içerisinde en kararlı, hataya en dirençli ve güvenilir performansı **Random Forest** algoritması sergilemiştir.



Şekil 11: Tüm Modeller-ROC Eğrisi Grafiği

9. KAYNAKÇA

- [1] Patricio, M., Pereira, J., Crisostomo, J., Matafome, P., Gomes, M., Seica, R., & Caramelo, F. (2018). Using Resistin, glucose, age and BMI to predict the presence of breast cancer. *BMC Cancer*, 18(1), 29. <https://doi.org/10.1186/s12885-017-3877-1>
- [2] Aslan, M. F., Çelik, Y., Sabancı, K., & Durdu, A. (2018). Breast cancer diagnosis by different machine learning methods using blood analysis data. *International Journal of Intelligent Systems and Applications in Engineering*, 6(4), 289-293
- [3] Karabatak, M. (2015). A new classifier for breast cancer detection based on Naive Bayesian. *Measurement*, 72, 32-36.
- [4] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- [5] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- [6] Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1), 21-27.
- [7] Quinlan, J. R. (1986). Induction of Decision Trees. *Machine Learning*, 1(1), 81-106.
- [8] UCI Machine Learning Repository. Breast Cancer Coimbra Data Set. <https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Coimbra>