

İSTANBUL TOPKAPI ÜNİVERSİTESİ

MÜHENDİSLİK FAKÜLTESİ YAZILIM MÜHENDİSLİĞİ BÖLÜMÜ

MAKİNE ÖĞRENMESİ ALGORİTMALARI İLE KANSER SINIFLANDIRMASI FİNAL PROJE MAKALESİ

*Özellik Mühendisliği ve İleri Seviye Makine Öğrenmesi Algoritmaları ile
Meme Kanseri Sınıflandırması:
DataR2 Veri Seti Üzerinde Kapsamlı Bir Karşılaştırma*

Hazırlayanlar:

22040301030 – Şevval ARSLAN - sevvalarslan@stu.topkapi.edu.tr

23040301108 - Zeynep EKİNCİ - zeynepekinci@stu.topkapi.edu.tr

23040301066 - Senanur TURUNÇ - senanurturunc@stu.topkapi.edu.tr

22040301070 - Utku GÜZELLER - utkuguzeller@stu.topkapi.edu.tr

22040301162 – Youmna HAWAJ - yournahawaj@stu.topkapi.edu.tr

Ders: Makine Öğrenmesi | Öğretim Üyesi:

Mahsa TORKAMANIAN AFSHAR

Bahar, 2026

Özellik Mühendisliği ve İleri Seviye Makine Öğrenmesi Algoritmaları ile Meme Kanseri Sınıflandırması: DataR2 Veri Seti Üzerinde Kapsamlı Bir Karşılaştırma

Şevval Arslan¹, Zeynep Ekinci¹, Senanur Turunç¹, Utku Güzeller¹, Youmna Hawaj¹

¹Yazılım Mühendisliği Bölümü, Mühendislik Fakültesi, İstanbul Topkapı Üniversitesi, İstanbul, Türkiye
sevvalarslan@stu.topkapi.edu.tr, zeynepkinci@stu.topkapi.edu.tr, senanurturunc@stu.topkapi.edu.tr,
utkuguzeller@stu.topkapi.edu.tr, yournahawaj@stu.topkapi.edu.tr

Özet—Bu çalışmada, Coimbra Meme Kanseri (DataR2) veri seti üzerinde özellik mühendisliği (Feature Engineering) ve ileri seviye makine öğrenmesi algoritmaları kullanılarak kapsamlı bir kanser sınıflandırması gerçekleştirilmiştir. Orijinalinde 116 hastadan oluşan ve 9 biyomedikal özellik barındıran veri seti; HOMA-IR İndeksi, Leptin/Adiponektin Oranı ve çeşitli metabolik endeksler gibi klinik literatürden türetilen 7 adet yeni klinik değişken ve logaritmik dönüşümler eklenerek toplam özellik sayısı 16'ya çıkarılmıştır. Aykırı değer temizleme, RobustScaler ölçeklendirmesi, SelectKBest özellik seçimi ($k=10$) ve SMOTE sınıf dengeleme işlemleri veri sızıntısını önleyecek biçimde sıralanmıştır. Lojistik Regresyon, SVM ve Voting Ensemble başta olmak üzere sekiz algoritma, 10-katlı çapraz doğrulama ve GridSearchCV hiperparametre optimizasyonu ile değerlendirilmiştir. Lojistik Regresyon ve Voting Ensemble algoritmaları %81.82 doğruluk, 0.8462 F1 skoru ve 0.8333 AUC değerleriyle en yüksek performansı vermiştir. Bulgular, algoritma seçiminden bağımsız olarak veriyi doğru işleme sürecinin, özellikle özellik mühendisliği ve uygun veri ön işleme adımlarının, sınıflandırma başarısının temel belirleyicisi olduğunu ortaya koymuştur.

Anahtar Kelimeler—Makine Öğrenmesi, Meme Kanseri Teşhisi, Özellik Mühendisliği, SMOTE, Lojistik Regresyon, SVM, Voting Ensemble, DataR2

I. GİRİŞ

Meme kanseri, dünya genelinde kadınlarda görülen en yaygın kanser türlerinden biridir. Erken ve doğru teşhis, hayatta kalma oranları üzerinde doğrudan belirleyici bir etki yaratmaktadır. Geleneksel klinik yöntemlerden olan mamografi, biyopsi, ultrasonografi gibi yöntemler güvenilir sonuçlar vermektedir. Fakat bunlar zaman alıcı, pahalı ve hasta açısından yıpratıcı süreçleri de beraberinde getirmektedir. Bu durum, rutin kan tahlili değerlerinden hareketle kanser riskini öngörebilecek düşük maliyetli, erişilebilir ve yüksek performanslı tanı destekleme araçlarına olan ihtiyacı giderek artırmaktadır [1,4].

İnsan gözünün aynı anda değerlendiremeyeceği çok boyutlu glikoz, insülin direnci ve vücut kitle indeksi arasındaki etkileşimi gibi biyomedikal ilişkileri makine öğrenmesi algoritmaları matematiksel modeller aracılığıyla öğrenebilmektedir [2]. Bu alandaki

çalışmaların büyük çoğunluğu ham veriler üzerinde model kurmakla yetinmekte; veri sızıntısı riskini ve sınıf dengesizliği problemini göz ardı etmektedir. Sistematik bir pipeline mimarisinin yokluğu, raporlanan performans değerlerinin gerçek klinik uygulamayı yansıtmıyorsa tartışılmalıdır.

Bu çalışmanın temel amacı, DataR2 veri seti üzerinde güvenilir bir sınıflandırma çerçevesi oluşturmaktır. Bu kapsamda veri sızıntısının önlenmesi, sınıf dengesinin korunması ve özellik uzayının klinik bilgilerle zenginleştirilmesi hedeflenmiştir. Çalışmada dört temel katkı öne çıkmaktadır. Bunlardan ilki tıbbi literatürdeki metabolik formüller aracılığıyla 9 orijinal özelliğin 16 boyuta taşınmasıdır. İkincisi ise SMOTE'un SelectKBest'ten sonra uygulanmasıyla veri sızıntısının engellenmiş olmasıdır. Üçüncü olarak sekiz algoritmanın tek tip ve güvenilir bir protokol altında karşılaştırılmasıdır. Son olarak da farklı makine öğrenmesi modellerinin klinik açıdan kritik hata türleri bakımından karşılaştırılmasıdır.

II. İLGİLİ ÇALIŞMALAR

DataR2 veri setini literatüre kazandıran Patricio ve arkadaşları [1], Lojistik Regresyon, Rastgele Orman ve SVM algoritmaları ile yaptıkları çalışmada 0.83 AUC değerine ulaşmış; Resistin, Glikoz, Yaş ve BMI değişkenlerinin en belirleyici özellikler olduğunu raporlamıştır. Ancak söz konusu çalışmada özellik mühendisliği adımları uygulanmamış, sınıf dengesizliği dikkate alınmamıştır.

Aslan ve arkadaşları [4], aynı veri seti üzerinde SVM ve Rastgele Orman yöntemleriyle %85 doğruluk elde etmiştir. Karabatak [5] ise özellik seçimi temelli bir yaklaşımla KNN ve Naive Bayes modellerini %97 doğrulukla test etmiştir. Bu yüksek değerlerin sınırlı test seti büyüklüğünden kaynaklanmış olabileceği ve çapraz doğrulama protokolü uygulanmadığı göz önüne alındığında, sonuçların gerçek dünya performansını tam olarak yansıtmadığı söylenebilmektedir.

Mevcut literatür incelendiğinde, DataR2 üzerindeki çalışmaların büyük bölümünde SMOTE ve pipeline mimarisi gibi veri sızıntısını önleyici mekanizmalara yer verilmediği dikkat çekmektedir. Bu eksiklikleri

gidermek amacıyla gerçekleştirilen çalışmamız, hem vize aşamasında kullanılan temel algoritmaları (KNN, Naive Bayes, Karar Ağacı, Rastgele Orman) hem de final aşamasında geliştirilen ileri seviye modelleri (Lojistik Regresyon, SVM, ANN, Voting Ensemble) aynı pipeline çatısı altında değerlendirmektedir.

III. VERİ SETİ VE ÖN İŞLEME

A. Veri Setinin Yapısı

DataR2, Portekiz'de Coimbra Üniversitesi Hastanesi bünyesinde toplanan gerçek hasta verilerinden oluşmaktadır ve UCI Makine Öğrenmesi Deposu üzerinden kamuya açık bir veri setidir [6]. Bu veri seti, 116 kadın hastadan alınan kan örneklerinin laboratuvar analizlerini kapsar. 52 bireyi sağlıklı kontrol grubu (%44.8), 64 bireyi ise meme kanseri tanısı almış grup (%55.2) oluşturmaktadır.

Dokuz sayısal özellikten; Yaş (Age), Vücut Kitle İndeksi (BMI), Glikoz (Glucose), İnsülin (Insulin), İnsülin Direnci (HOMA), Leptin, Adiponektin, Resistin ve MCP.1 oluşan bu veri setinde eksik değer bulunmamaktadır. Ayrıca İnsülin, HOMA ve Resistin değişkenlerinde belirgin bir sağa çarpıklık (skewness) gözlemlenmiştir. Bu durum, kanser riski taşıyan küçük bir grubun çok yüksek biyobelirteç düzeylerine sahip olduğuna işaret etmektedir.

Tablo I. Veri Seti Özellikleri

Özellik	Açıklama	Birim
Age	Hastanın yaşı	Yıl
BMI	Vücut Kitle İndeksi	kg/m ²
Glucose	Kan şekeri seviyesi	mg/dL
Insulin	İnsülin seviyesi	μIU/mL
HOMA	İnsülin direnci ölçütü	Sayısal
Leptin	Yağ dokusu hormonu	ng/mL
Adiponectin	İnsülin duyarlılığı hormonu	μg/mL
Resistin	İnsülin direnciyle ilişkili protein	ng/mL
MCP.1	İltihaplama belirteci	pg/dL

B. Özellik Mühendisliği

Makine öğrenmesi modellerinin başarısı doğrudan veri kalitesine ve özellik zenginliğine bağlıdır. Bu nedenle ham kan değerleri, tıbbi literatürdeki metabolik sendrom formülleri kullanılarak yeni özelliklerle desteklenmiş ve çarpık dağılımlı değişkenlerle logaritmik dönüşüm uygulanmıştır [1,8]. Böylece 9 olan özellik sayısı 16'ya yükseltilmiştir.

HOMA_IR_Index özelliği, klinik insülin direncini ölçen standart formül olan (Glikoz × İnsülin) / 405 kullanılarak türetilmiştir. LA_Ratio (Leptin/Adiponektin Oranı) meme kanseri riskinde en güçlü adipokin belirteci olarak kabul görmektedir.

Glucose_BMI_Ratio, kan şekeri ile obezite arasındaki etkileşimi modellemek amacıyla eklenmiştir. Yaş ile BMI'nin çarpımından elde edilen Age_BMI etkileşim özelliği ise yaşa bağlı obezite-kanser ilişkisini yakalamaktadır. Logaritmik dönüşümler (log(1+x)) uygulanarak İnsülin, HOMA ve Resistin değişkenlerinin dağılımı normale yaklaştırılmış, çoklu doğrusallık (multicollinearity) riski azaltılmıştır.

C. Pipeline Mimarisi ve Veri Sızıntısının Önlenmesi

Veri ön işleme adımlarının doğru sıralanması, modelin gerçek klinik performansını güvence altına alan en kritik metodolojik karar olarak değerlendirilmektedir. Uygulanan pipeline şu adımları kapsamaktadır:

- (1) Z-skoru > 3.5 olan aykırı değerlerin temizlenmesi. Bu aşamada örnek sayısı 116'dan 110'a düşmüştür.
- (2) RobustScaler ile medyan-IQR tabanlı ölçeklendirme. Bu sayede uç değerlerin ölçekleyiciyi bozması engellenmiştir [8].
- (3) ANOVA F-testine dayalı SelectKBest algoritmasıyla en anlamlı 10 özelliğin seçilmesi (k=10).
- (4) Seçilen özellikler üzerinde SMOTE uygulanarak sınıf dengesinin sağlanması.
- (5) StratifiedKFold çapraz doğrulama (10-katlı) ve GridSearchCV ile hiperparametre optimizasyonu [8].

SMOTE'un özellik seçiminden önce değil sonra uygulanması bilinçli bir tercihtir. Eğer SMOTE önce yapılırdı, sentetik veriler özellik seçimini manipüle edecek ve test setine ilişkin bilgi eğitim sürecine sızması olacaktı. Kullandığımız sıralama, literatürde sıkça rastlanan veri sızıntısı hatasından kaçınmanın en güvenilir yoludur [8].

IV. MAKİNE ÖĞRENMESİ ALGORİTMALARI

A. Lojistik Regresyon

Lojistik Regresyon, girdiler ile hedef değişken arasındaki olasılıksal ilişkiyi doğrusal bir çerçevede modelleyen ve tıbbi teşhis uygulamalarında yorumlanabilirliği yüksek tutması nedeniyle sıklıkla tercih edilen bir algoritmadır [2]. Bu çalışmada C düzenleme katsayısı GridSearchCV ile optimize edilmiş, L2 (Ridge) cezalandırması kullanılmıştır. Özellik katsayıları incelendiğinde modelin Metabolic_Risk ve Log_Insulin değişkenlerine en yüksek ağırlığı verdiği görülmüştür.

Elde ettiğimiz sonuçlar açısından değerlendirildiğinde, Lojistik Regresyon modelinin beklentinin üzerinde bir performans sergilediği söylenebilir. Düşük eğitim-test farkı sayesinde model, yeni verilere karşı sağlam bir genelleme yeteneği kazanmıştır. Test setinde %81.82 doğruluk ve 0.8462 F1 skoru ile çalışmanın en başarılı modelleri arasına girmiştir. Bu sonuç, doğrusal yapısına karşın bu denli güçlü bir performans ortaya koyması bakımından dikkat çekicidir. Bunun temel sebebinin özellik mühendisliği aşamasında türetilen metabolik değişkenler olduğunu düşünüyoruz; bu özellikler

sınıflar arasındaki ayrımı belirgin biçimde kolaylaştırmıştır.

B. Destek Vektör Makineleri (SVM)

SVM, sınıflar arasındaki marjını en büyükleyecek hiper-düzlemleri arayan güçlü bir sınıflandırıcıdır [8]. Veri setimizin doğrusal olmayan yapısı nedeniyle RBF (Radial Basis Function) kernel tercih edilmiş; Gamma ve C parametreleri GridSearchCV ile optimize edilmiştir.

Karmaşıklık matrisi detaylı incelendiğinde, modelin test setindeki 12 gerçek hastadan 10'unu başarıyla tespit ettiği, yalnızca 2 hastayı gözden kaçırdığı görülmektedir. Klinik açıdan değerlendirildiğinde bu tablo oldukça önemlidir. Medikal sistemlerde hasta kaçırma hatası (False Negative) geri dönüşü olmayan sonuçlara yol açabilmektedir. SVM ayrıca 0.8417 AUC değeriyle sınıfları ayırt etme konusunda da güçlü bir profil çizmiştir [3,8]. Genel olarak bakıldığında, SVM'in bu veri seti üzerinde kararlı ve güvenilir sonuçlar ürettiğini, özellikle klinik karar destek sistemlerine entegrasyon için ciddi bir aday olduğunu söylemek mümkündür.

C. Voting Ensemble (Soft Voting)

Hiçbir makine öğrenmesi algoritmasının her koşulda üstün olmadığı gerçeğinden hareketle, Lojistik Regresyon, SVM ve ANN modellerinin olasılık tahminlerinin ortalamasını alan bir Soft Voting mekanizması kurulmuştur [9]. Bu yapının temel amacı, bireysel modellerin zayıf kaldığı noktalarda diğerlerinin devreye girmesini sağlamaktır [9,10].

Sonuçlara bakıldığında Voting Ensemble modelinin bu amacı büyük ölçüde karşıladığı görülmektedir. Test setinde %81.82 doğruluk ve 0.8462 F1 skoru elde etmesinin yanı sıra, eğitim ve test doğrulukları arasındaki farkın yalnızca 0.0040 olması dikkat çekicidir. Bu fark, incelediğimiz modeller arasındaki en düşük değerdir ve ensemble yaklaşımının aşırı öğrenmeyi bastırmadaki etkinliğini açıkça ortaya koymaktadır. Bize göre bu model, tek başına en yüksek skoru vermese de tutarlılığı ve klinik güvenilirliği açısından pratikte tercih edilmesi gereken yapıdır.

V. SONUÇLAR VE BULGULAR

A. Genel Performans Karşılaştırması

Tüm modeller, eğitim sürecinde hiç görülmemiş %20'lik test seti üzerinde değerlendirilmiştir. Accuracy, Precision, Recall, F1-Score, ROC-AUC ve çapraz doğrulama (CV) F1 skoru metrikleri bir arada raporlanmıştır. Tablo II'de tüm algoritmalara ait performans metrikleri bulunmaktadır.

Tablo II. Tüm Modellerin Detaylı Performans Metrikleri

Model	Accuracy	Precision	Recall	F1	AUC	CV F1
Lojistik Regresyon	0.8182	0.7857	0.9167	0.8462	0.8250	0.7112
Voting Ensemble	0.8182	0.7857	0.9167	0.8462	0.8333	0.7150
SVM	0.7727	0.7692	0.8333	0.8000	0.8417	0.7308
Random Forest	0.7273	0.7500	0.7500	0.7500	0.7667	0.7806
Decision Tree	0.7273	0.8000	0.6667	0.7273	0.8208	0.7258
ANN	0.6818	0.6923	0.7500	0.7200	0.8500	0.7650
KNN	0.6364	0.7500	0.5000	0.6000	0.7917	0.7367
Naive Bayes	0.5909	0.6667	0.5000	0.5714	0.7833	0.6444

Tablo II incelendiğinde, Lojistik Regresyon ve Voting Ensemble modellerinin %81.82 doğruluk ve 0.8462 F1 skoru ile birlikte en üst sıraya yerleştiği görülmektedir. Çapraz doğrulama sonuçlarının test seti sonuçlarına yakın olması, algoritmaların veri ezberleme (overfitting) eğiliminde olmadığını göstermektedir.

B. Vize ve Final Aşaması Karşılaştırması

Tablo III. Vize ve Final Modellerinin Gelişim Karşılaştırması

Kriter	Vize Aşaması	Final Aşaması
En İyi Accuracy	0.7083 (RF/DT)	0.8182 (LR/Ensemble)
En İyi F1-Score	0.6957	0.8462
En İyi AUC	0.7500	0.8500 (ANN)
Feature Engineering	Yok	7 türetilmiş özellik + log dönüşümler (toplam 16 feature)
Ölçeklendirme	StandardScaler	RobustScaler
Özellik Seçimi	k=5	k=10
Sınıf Dengeleme	Yok	SMOTE
Çapraz Doğrulama	5-fold	10-fold

Tablo III, özellik mühendisliği ve sınıf dengeleme tekniklerinin modele kattığı değeri sayısal olarak ortaya koymaktadır. En iyi doğruluk oranı %70.83'ten %81.82'ye, F1 skoru ise 0.6957'den 0.8462'ye yükselmiştir. Bu artışın salt algoritma değişikliğinden değil, veriyi doğru işleme sürecinden kaynaklandığı görülmektedir. Ayrıca bu veri işleme süreci sayesinde

vizede en yüksek değerleri veren Random Forest algoritmasının sonuçları da iyileşmiştir.

C. Overfitting Analizi

Tablo IV. İleri Seviye Modellerin Aşırı Öğrenme Kontrol Tablosu

Model	Train Acc	Test Acc	Fark	Değerlendirme
Lojistik Regresyon	0.8111	0.8182	0.0071	İyi Genelleme
SVM	0.7889	0.7727	0.0162	İyi Genelleme
ANN	0.7778	0.6818	0.0960	İyi Genelleme
Voting Ensemble	0.8222	0.8182	0.0040	İyi Genelleme

Eğitim ve test doğrulukları arasındaki fark tüm modellerde %10'un altında kalmıştır. Voting Ensemble modelinde eğitim ve test doğrulukları arasındaki farkın oldukça az olması, modelin iyi genelleme yeteneğine sahip olduğunu göstermektedir.

D. Eşik Değeri Optimizasyonu

Klinik karar sistemlerinde varsayılan 0.5 eşiği her zaman optimum sonucu vermemektedir [2]. Bu nedenle 0.20-0.80 aralığında tarama yapılmıştır. ANN modeli üzerinde farklı eşik değerleri denenmiş ve model performansının eşik seçimine duyarlı olduğu gözlemlenmiştir. Bu durum, tıbbi karar destek sistemlerinde eşik optimizasyonunun önemli bir parametre olduğunu göstermektedir.

E. Klinik Hata Analizi (False Negative)

Medikal sınıflandırmada Yanlış Negatif hatası (kanserli hastaya sağlıklı demek), Yanlış Pozitif hatadan çok daha ağır klinik sonuçlara yol açmaktadır. Bu nedenle FN sayısı ayrıca incelenmiştir. Lojistik Regresyon ve Voting Ensemble modelleri test setinde yalnızca 1 hastayı yanlış sınıflandırmıştır. Bu durum, bu iki modelin klinik açıdan kritik olan Yanlış Negatif (FN) hatalarını düşük seviyede tutabildiğini göstermektedir [1].

VI. TARTIŞMA

Bu çalışmanın sonuçları incelendiğinde, Lojistik Regresyon ve Voting Ensemble modellerinin benzer doğruluk ve F1 skorları elde ettiği görülmüştür. Bu durum, Voting Ensemble modelinin performansında Lojistik Regresyonun belirleyici bir rol oynadığını göstermektedir. Bunun yanında SVM ve ANN modellerinin de özellikle daha karmaşık örneklerin sınıflandırılmasında modele katkı sağladığı düşünülmektedir.

Naive Bayes'in en düşük performansı sergilemesi beklenen bir sonuçtur. HOMA_IR_Index gibi yeni türetilen özellikler, İnsülin ve Glikoz ile güçlü matematiksel korelasyon içermektedir. Naive Bayes ise tüm özelliklerin istatistiksel bağımsızlığını varsayar

[5,11]. Bu varsayımın ihlali, modelin olasılık tahminlerini bozmuş ve sınıflandırma performansını sınırlandırmıştır.

ANN modelinin test doğruluğunun (0.6818) eğitim doğruluğundan (0.7778) belirgin biçimde düşük kalması, küçük veri setlerinin derin modeller için yeterli öğrenme kapasitesi sunmadığını belirtmektedir. Gelecek çalışmalarda veri seti büyüdükçe ANN mimarilerinin daha avantajlı konuma geleceği öngörülmektedir. Benzer yönde bir gözlem olarak, Decision Tree modelinin AUC değerinin (0.8208) accuracy değerine (0.7273) kıyasla daha yüksek çıkması da çarpıcıdır. Bu durum, ağacın sınıf olasılıklarını binary threshold kararından daha iyi ayırt ettiğini göstermektedir. Öte yandan, Lojistik Regresyon modelinin çapraz doğrulama F1 skoru (0.7112) ile test seti F1 skoru (0.8462) arasındaki fark dikkat çekicidir. Test setinin küçük boyutu (22 örnek) nedeniyle çapraz doğrulama ortalamasından sapmalar gözlemlenmiştir; bu durum sonuçların istatistiksel kırılganlığına işaret etmektedir.

Özellik seçim analizi incelendiğinde, Glucose_BMI_Ratio (F=24.15) ve Log_HOMA (F=18.24) değişkenlerinin kanser sınıflandırmasında en ayırt edici parametreler olduğu görülmektedir. Bu bulgu, metabolik sendrom göstergelerinin meme kanseri riskiyle olan ilişkisini destekleyen klinik çalışmalarla örtüşmektedir [1,4].

VII. SONUÇ

Bu çalışmada DataR2 veri seti üzerinde veri sızıntısını önlemeye yönelik bir pipeline mimarisi, kapsamlı özellik mühendisliği ve sekiz farklı makine öğrenmesi algoritmasını kapsayan bütünlük bir sınıflandırma çerçevesi oluşturulmuştur. Elde edilen bulgular, model seçiminin önemli olmakla birlikte asıl belirleyicinin veriyi doğru işleme süreci — yani RobustScaler, SelectKBest ve SMOTE adımlarının doğru sıralanma biçimi — olduğunu açıkça ortaya koymuştur [7,8].

Özellik mühendisliği aşamasında tıbbi literatürden türetilen metabolik değişkenler (HOMA_IR_Index, LA_Ratio, Glucose_BMI_Ratio vb.), sınıflar arasındaki ayrımı belirgin biçimde güçlendirmiş; bu sayede Lojistik Regresyon gibi doğrusal yapıya sahip bir modelin karmaşık algoritmalarla rekabet edebilir hale gelmesi sağlanmıştır [2]. Bu bulgu, algoritma karmaşıklığından önce veri kalitesini iyileştirmenin daha verimli bir strateji olduğunu desteklemektedir. En yüksek performansı %81.82 doğruluk, 0.8462 F1 skoru ve 0.8333 AUC değeriyle Voting Ensemble ile Lojistik Regresyon modelleri ortaklaşa sağlamış; klinik açıdan kritik olan Yanlış Negatif hatalar yalnızca 1 vakayla sınırlı tutulmuştur [1,3].

ANN modelinin küçük veri setinde (110 örnek) beklenen performansı gösterememesi, derin öğrenme mimarilerinin yeterli genelleme kapasitesi için daha geniş örneklem hacmine ihtiyaç duyduğunu bir kez daha teyit etmiştir [12]. Çalışmanın başlıca sınırlılıkları

arasında tek bir hastaneden elde edilen sınırlı veri büyüklüğü ve dış doğrulama (external validation) yapılamamış olması sayılabilir; bu durum, sonuçların farklı popülasyonlara genellenebilirliğini kısıtlamaktadır.

Geliştirilen model, hastaların rutin kan tahlili değerleri üzerinden meme kanseri riskinin öngörülmesine olanak tanımakta ve hastane bilgi sistemlerine entegrasyon için metodolojik açıdan sağlam bir altyapı sunmaktadır [1]. Gelecek çalışmalarda veri setinin farklı klinik merkezlerden elde edilen kayıtlarla genişletilmesi, çok merkezli dış doğrulama protokolleri uygulanması ve açıklanabilir yapay zeka (XAI) yöntemleriyle model kararlarının klinisyenlere şeffaf biçimde sunulması planlanmaktadır [12]. Özellikle SHAP değerleri gibi yorumlanabilirlik araçlarının entegrasyonu, klinik kullanım için önemli bir adım olacaktır.

KAYNAKÇA

- [1] M. Patricio, J. Pereira, J. Crisostomo, P. Matafome, M. Gomes, R. Seica ve F. Caramelo, "Using Resistin, glucose, age and BMI to predict the presence of breast cancer," *BMC Cancer*, c. 18, s. 1, m. 29, 2018. DOI: 10.1186/s12885-017-3877-1.
- [2] S. Dreiseitl ve L. Ohno-Machado, "Logistic regression and artificial neural network classification models: a methodology review," *Journal of Biomedical Informatics*, c. 35, s. 5-6, ss. 352-359, 2002.
- [3] C. Ferri, J. Hernández-Orallo ve M. A. Salido, "Volume under the ROC surface for multi-class problems," *Lecture Notes in Computer Science (Machine Learning: ECML 2003)*, c. 2837, ss. 108-120, 2003.
- [4] M. F. Aslan, Y. Çelik, K. Sabancı ve A. Durdu, "Breast cancer diagnosis by different machine learning methods using blood analysis data," *International Journal of Intelligent Systems and Applications in Engineering*, c. 6, s. 4, ss. 289-293, 2018.
- [5] M. Karabatak, "A new classifier for breast cancer detection based on Naive Bayesian," *Measurement*, c. 72, ss. 32-36, 2015.
- [6] UCI Machine Learning Repository, Breast Cancer Coimbra Data Set. [Online]. Erişim: <https://archive.ics.uci.edu/dataset/451/breast+cancer+coimbra> [Erişim tarihi: 12 Mayıs 2025].
- [7] N. V. Chawla, K. W. Bowyer, L. O. Hall ve W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, c. 16, ss. 321-357, 2002.
- [8] F. Pedregosa ve ark., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, c. 12, ss. 2825-2830, 2011.
- [9] V. N. Vapnik, *Statistical Learning Theory*. Wiley, New York, 1998.
- [10] L. I. Kuncheva ve C. J. Whitaker, "Measures of diversity in classifier ensembles and their relationship with the ensemble accuracy," *Machine Learning*, c. 51, ss. 181-207, 2003.
- [11] D. Hand ve K. Yu, "Idiot's Bayes – not so stupid after all?," *International Statistical Review*, c. 69, s. 3, ss. 385-399, 2001.
- [12] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, 2. baskı. O'Reilly Media, 2019.