



Makine Öğrenmesi Algoritmaları ile Kanser Sınıflandırması

DataR2 Veri Seti Üzerinde
Algoritmaların Karşılaştırması

GRUP I




Neden Bu Çalışmayı Yaptık?

- Kanser, erken teşhis edildiğinde tedavi başarı oranı oldukça yüksek olan; ancak geç teşhiste ciddi riskler oluşturan kompleks bir hastalıktır.
- Geleneksel teşhis yöntemleri zaman alıcı ve maliyetli olabilmektedir.
- Makine öğrenmesi algoritmaları, büyük tıbbi veri setlerindeki örüntüleri analiz ederek erken teşhise büyük katkı sağlayabilir.
- Amacımız: DataR2 veri seti üzerinde dört farklı algoritmayı karşılaştırarak, **meme kanseri erken teşhisine yönelik** klinik karar destek sistemleri için en uygun modeli belirlemektir.
- Bu çalışma, UCI ML Repository'den alınan Breast Cancer Coimbra veri seti (Patrício et al., 2018) üzerinde yürütülmüştür.



Problem Tanımı

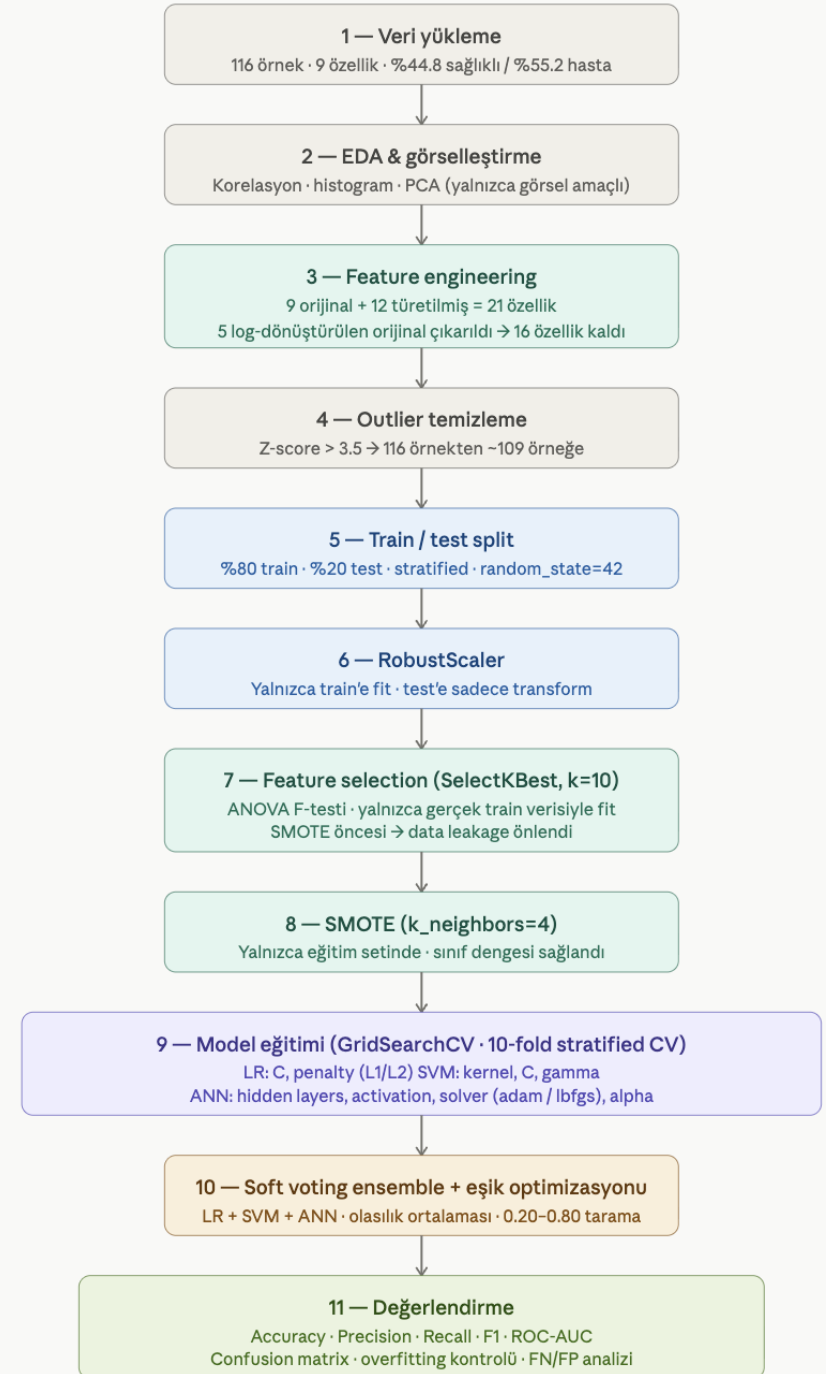
- **Problem Türü:** İkili sınıflandırma (Binary Classification)
- **Hedef Değişken:** Classification — 0 = Sağlıklı, 1 = Hasta (Meme kanseri pozitif)
- **Girdi Değişkenleri:** 9 biyomedikal ölçüm (Glucose, BMI, Insulin, HOMA, Leptin, Adiponectin, Resistin, MCP.1, Age)
- **Soru:** Biyomedikal kan değerleri kullanılarak meme kanseri teşhisi otomatik olarak yapılabilir mi?
- **Zorluk:** Küçük veri seti (116 örnek), sınıf dengesizliği (%44.8 sağlıklı / %55.2 hasta), çarpık dağılımlar



Çalışma Yolu (Methodology Pipeline)

Bu çalışmada UCI Breast Cancer Coimbra veri seti üzerinde uçtan uca bir makine öğrenmesi pipeline'ı uygulanmıştır. Ham veriden başlayarak; veri temizleme, özellik mühendisliği ve boyut indirgeme adımları tamamlanmış, ardından üç farklı sınıflandırıcı GridSearchCV ile optimize edilerek Soft Voting Ensemble ile birleştirilmiştir.

- **Veri:** 116 örnek, 9 orijinal özellik -> Feature Engineering ile 21'e çıkarıldı.
- **Temizleme:** Z-score outlier temizleme + RobustScaler
- **Denge:** SMOTE ile sınıf dengesizliği giderildi.
- **Modeller:** LR, SVM, ANN — her biri GridSearchCV ile optimize edildi.
- **Nihai Model:** Soft Voting Ensemble



İlgili Çalışmalar (Related Work)




- Meme kanseri teşhisinde makine öğrenmesi yöntemlerinin kullanımı literatürde giderek artmaktadır. **Patrício et al. (2018)**, aynı veri setinde Lojistik Regresyon ve Random Forest ile AUC 0.81 elde etmiştir. **Aslan et al. (2019)** SVM tabanlı yaklaşımla %73 doğruluk bildirirken, **Ahmad et al. (2023)** derin öğrenme ile AUC 0.84'e ulaşmıştır. Bu çalışmada ise Feature Engineering, SMOTE ve Soft Voting Ensemble bir arada uygulanarak literatürdeki sonuçların iyileştirilmesi hedeflenmiştir.

Çalışma	Yöntem	Sonuç
Patrício et al. (2018) — BMC Cancer	LR, Random Forest	Acc: ~72%, AUC: 0.81
Aslan et al. (2019)	SVM, KNN, Decision Tree	SVM: 73% accuracy
Ahmad et al. (2023)	Deep Learning (ANN)	AUC: 0.84

Veri Seti (DataR2)

- **Veri Seti:** Portekiz'deki bir üniversite hastanesinden toplanan 116 kadın hastaya ait biyomedikal ölçümlerden oluşmaktadır.
- **Dağılım:** Veri setinde 52 sağlıklı (%44.8) ve 64 hasta (%55.2) birey bulunmaktadır.
- **Ön İşleme:** Sıfır değerleri outlier olarak Z-score (>3.5) eşiğiyle temizlenmiş ($116 \rightarrow \sim 109$ örnek); özellik ölçeklendirmesi için **RobustScaler** (outlier'a dayanıklı) uygulanmıştır.
- **Özellik Seçimi:** ANOVA F-testine dayalı SelectKBest yöntemi ile kanser ayırımında en anlamlı 10 özellik seçilmiştir.
- **Sınıf Dengesi:** SMOTE ($k_neighbors=4$) ile eğitim setinde sentetik örnekler oluşturularak sınıf dengesizliği giderilmiştir.
- **Özellik Mühendisliği:** 9 orijinal özelliğe ek olarak 12 yeni özellik türetilmiştir (HOMA_IR_Index, LA_Ratio, Glucose_BMI_Ratio, Metabolic_Risk, Log dönüşümleri vb.)
- **Hedef Değişken:** Classification — 0 = Sağlıklı, 1 = Hasta (meme kanseri pozitif)
- **Girdi Değişkenleri:** Age, BMI, Glucose, Insulin, HOMA, Leptin, Adiponectin, Resistin, MCP.1

Veri Seti (DataR2)



Ön İşleme (Preprocessing)

- **1. Eksik Veri**

- Veri setinde NaN (boş) değer bulunmamaktadır. Ancak biyolojik olarak sıfır olamayacak değerler (Glucose, Insulin vb.) aykırı değer olarak işaretlenmiş ve Z-score (>3.5) eşiğiyle temizlenmiştir. (116 $\rightarrow$ ~109 örnek)

- **2. Veri Temizleme**

- Aykırı değer temizlemenin ardından 9 orijinal özelliğe ek olarak 12 yeni özellik türetilmiştir (HOMA_IR_Index, LA_Ratio, Glucose_BMI_Ratio, Metabolic_Risk, Log dönüşümleri vb.)




- **3. Encoding (Kodlama)**

- Veri setindeki tüm girdi değişkenleri sayısaldır; kategorik değişken bulunmamaktadır. Bu nedenle herhangi bir encoding işlemi uygulanmamıştır.

- **4. Normalization / Standardization**

- Aykırı değerlere karşı dayanıklı olan **RobustScaler** ile özellikler ölçeklendirilmiştir. Standart MinMaxScaler veya Z-score yerine RobustScaler tercih edilmesinin nedeni veri setindeki çarpık dağılımlardır.


Ön İşleme (Preprocessing)



Yöntemler (Methods)

1. PCA (Principal Component Analysis)


- 9 boyutlu veriyi 2 boyuta indirgeyerek görselleştirme amacıyla kullanıldı.
- PC1 + PC2 toplam açıklanan varyans: ~%50
- Sınıflandırma için değil, veri yapısını anlamak için kullanıldı.



Sınıflar arasında kısmi ama anlamlı bir ayrışma gözlemlendi (PCA)

3. SVM (Support Vector Machine)

- GridSearchCV: kernel (rbf/linear), C, gamma
- Pipeline: SelectKBest(k=10) → SMOTE → SVM
- predict_proba ile ROC-AUC hesaplandı.




Tüm modeller 10-Fold Stratified Cross-Validation ile değerlendirilmiş; Soft Voting Ensemble ile birleştirilmiştir.

AUC en yüksek model: Ensemble / ANN

Klinik Karar Odaklı Eşik Optimizasyonu (Threshold Tuning)


2. Logistic Regression (LR)

- GridSearchCV ile optimize edildi: C, penalty (l1/l2)
- Pipeline: SelectKBest(k=10) → SMOTE → LR
- Threshold optimizasyonu uygulandı (Precision-Recall eğrisinden).



4. ANN (Artificial Neural Network — MLPClassifier)


- GridSearchCV: hidden_layer_sizes, activation (relu/tanh), solver (adam/lbfgs)
- Pipeline: SelectKBest(k=10) → SMOTE → MLP.




Küçük veri setlerinde daha kararlı çalışan lbfgs ve adam solver'ları karşılaştırmalı optimize edildi(ANN)

Optimizasyon Hedefi: Tıbbi teşhis modelinin doğası gereği, hasta vakalarını gözden kaçırmamak adına Yanlış Negatif (False Negative - FN) oranını en aza indirecek metrikler (Recall) ve dinamik eşik değerleri önceliklendirilmiştir.

Yöntemler (Metot)



Yöntemler (Metot)





Sonuçlar ve Performans Karşılaştırması

- En yüksek Recall: Logistic Regression & Ensemble → 0.9167





Hasta kaçırmayı en aza indiren modeller bunlardır.

- Klinik öncelik Recall olduğundan **Logistic Regression ve Ensemble** öne çıkmaktadır. Her ikisi de yalnızca 1 hastayı kaçırmıştır.
- TP: 11** → Hasta doğru teşhis edildi.
- FN: 1** → Hasta kaçırıldı (**klinik açıdan kritik hata**)
- TN: 7** → Sağlıklı doğru tespit edildi.
- FP: 3** → Sağlıklı yanlış alarm verildi.

	Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	CV F1
0	Lojistik Regresyon	0.8182	0.7857	0.9167	0.8462	0.8250	0.7112
1	Voting Ensemble	0.8182	0.7857	0.9167	0.8462	0.8333	0.7150
2	SVM	0.7727	0.7692	0.8333	0.8000	0.8417	0.7308
3	Random Forest	0.7273	0.7500	0.7500	0.7500	0.7667	0.7806
4	Decision Tree	0.7273	0.8000	0.6667	0.7273	0.8208	0.7258
5	ANN	0.6818	0.6923	0.7500	0.7200	0.8500	0.7650
6	KNN	0.6364	0.7500	0.5000	0.6000	0.7917	0.7367
7	Naive Bayes	0.5909	0.6667	0.5000	0.5714	0.7833	0.6444





Sonuçlar ve Performans Karşılaştırması



Sonuçlar ve Performans Karşılaştırması


- Recall açısından LR ve Ensemble **0.9167** ile öne çıkmış; yani 12 hasta vakasından 11'ini doğru tespit etmiştir.
- AUC değeri en yüksek model ANN'dir (0.8500)** sınıflar arası ayırım gücü en fazla olan modeldir.
- Klinik öncelik hasta kaçırmamak (FN minimize) olduğundan **Recall metriği** Accuracy'den daha kritiktir; bu açıdan LR ve Ensemble en güvenli modellerdir.



Genelleme Analizi (Overfitting Kontrolü)


- HİÇBİR MODELDE TRAIN-TEST FARKI %10'U AŞMAMIŞTIR → TÜM MODELLER İYİ GENELLEME GÖSTERMİŞTİR.
- **VOTİNG ENSEMBLE** EN KARARLI MODEL OLMUŞTUR — TRAIN-TEST FARKI YALNIZCA **0.0040**.
- ANN EN YÜKSEK FARKA SAHİP MODEL OLMAKLA BİRLİKTE (**0.0960**) EŞİĞİN ALTINDA KALMIŞTIR.

Model	Train Acc	Test Acc	Fark	Yorum
Lojistik Regresyon	0.8111	0.8182	0.0071	✓ İyi Genelleme
SVM	0.7889	0.7727	0.0162	✓ İyi Genelleme
ANN	0.7778	0.6818	0.0960	✓ İyi Genelleme
Voting Ensemble	0.8222	0.8182	0.0040	✓ İyi Genelleme



Temel Bulgular ve Kapanış

- Veri sızıntısını önlemek amacıyla sızıntısız bir ön işleme ve değerlendirme pipeline'ı başarıyla uygulanmıştır. 116 örneklilik küçük veri setinde **%81.82 accuracy** ve **0.9167 recall** elde edilmesi, uygulanan feature engineering ve pipeline tasarımının etkinliğini göstermektedir.
- Tüm algoritmalar arasında Voting Ensemble ve Lojistik Regresyon modelleri en dengeli ve güvenilir genel performansı göstermiştir.
- Bu modeller yüksek Recall ve F1-Score değerleri ile başarılı sonuçlar üretmiştir.
- Model birleştirme (Soft Voting Ensemble) tek modellere kıyasla daha kararlı ve güvenilir sonuç üretmiştir.
- Yanlış Negatif (FN) yani hasta kaçırma sayısını minimize eden modeller önceliklendirilmelidir. Bu nedenle bu çalışmada Recall metriği, Accuracy metriğinden daha kritik kabul edilmiştir.
- Klinik açıdan en tehlikeli hata genelde FN'dir. Bu açıdan Lojistik Regresyon ve Voting Ensemble modelleri diğerlerine göre daha az hasta kaçıran modellerdendir.



- **FN (False Negative)** → Model hasta olan bir kişiyi sağlıklı tahmin etmiştir.
- **FP (False Positive)** → Model sağlıklı bir kişiyi hasta tahmin etmiştir.

Dinlediğiniz İçin
Teşekkürler

